Títulos e anotações

Hanna Rodrigues Ferreira

28 maio,2021

Vamos reproduzir os resultados do capítulo 5 do livro **Data Visualization - A pratical Introduction**. Os dados utilizados foram retirados deste github.

Adicionando Títulos e fazendo anotações

Vamos fazer uso da biblioteca a biblioteca `socviz` para fazer uso do datasets mencionados no livro.

```
knitr::opts_chunk$set(echo = TRUE)

library(gapminder)
library(tidyverse)
library(socviz)
```

Usando pipe para resumir dados

Utilizaremos o dataset **gss_sm** descrito neste site.

Podemos transformar os dados utilizando a biblioteca `dplyr`, contida na `tidyverse`. A seguir temos a tabela de das porcentagens de preferencias religiosas segundo cada região.

```
rel_by_region <- gss_sm %>%
    group_by(bigregion, religion) %>%
    summarize(N = n()) %>%
    mutate(freq = N/sum(N),
           pct = round((freq*100), 0))

rel_by_region
```

```
## # A tibble: 24 x 5
## # Groups:   bigregion [4]
##    bigregion religion       N    freq   pct
##    <fct>     <fct>      <int>   <dbl> <dbl>
##  1 Northeast Protestant   158 0.324      32
##  2 Northeast Catholic     162 0.332      33
##  3 Northeast Jewish        27 0.0553      6
##  4 Northeast None         112 0.230      23
##  5 Northeast Other         28 0.0574      6
##  6 Northeast <NA>           1 0.00205     0
##  7 Midwest   Protestant   325 0.468      47
```

```
##  8 Midwest   Catholic     172 0.247      25
##  9 Midwest   Jewish         3 0.00432     0
## 10 Midwest   None         157 0.226      23
## # ... with 14 more rows
```

O uso de pipes aumenta a legibilidade do código, fazendo a tarefa de checar a sanidade do nosso resultado mais fácil.

Se fizemos tudo na ordem correta, a soma das porcentagens por região deve resultar em 100% (considerando erros de arredondamento). Conforme mostrado a seguir:

```
rel_by_region %>%
    group_by(bigregion) %>%
    summarize(total = sum(pct))
```

```
## # A tibble: 4 x 2
##   bigregion total
##   <fct>     <dbl>
## 1 Northeast   100
## 2 Midwest     101
## 3 South       100
## 4 West        101
```

Podemos então trabalhar diretamente com as porcentagens e fazer um gráfico de barras das preferências religiosas por região:

```
p <- ggplot(rel_by_region,
            aes(x = bigregion, y = pct, fill = religion) )

p + geom_col( position = 'dodge') +
    labs(x = 'Region', y = 'Percent', fill = 'Religion') +
    theme(legend.position = 'top')
```

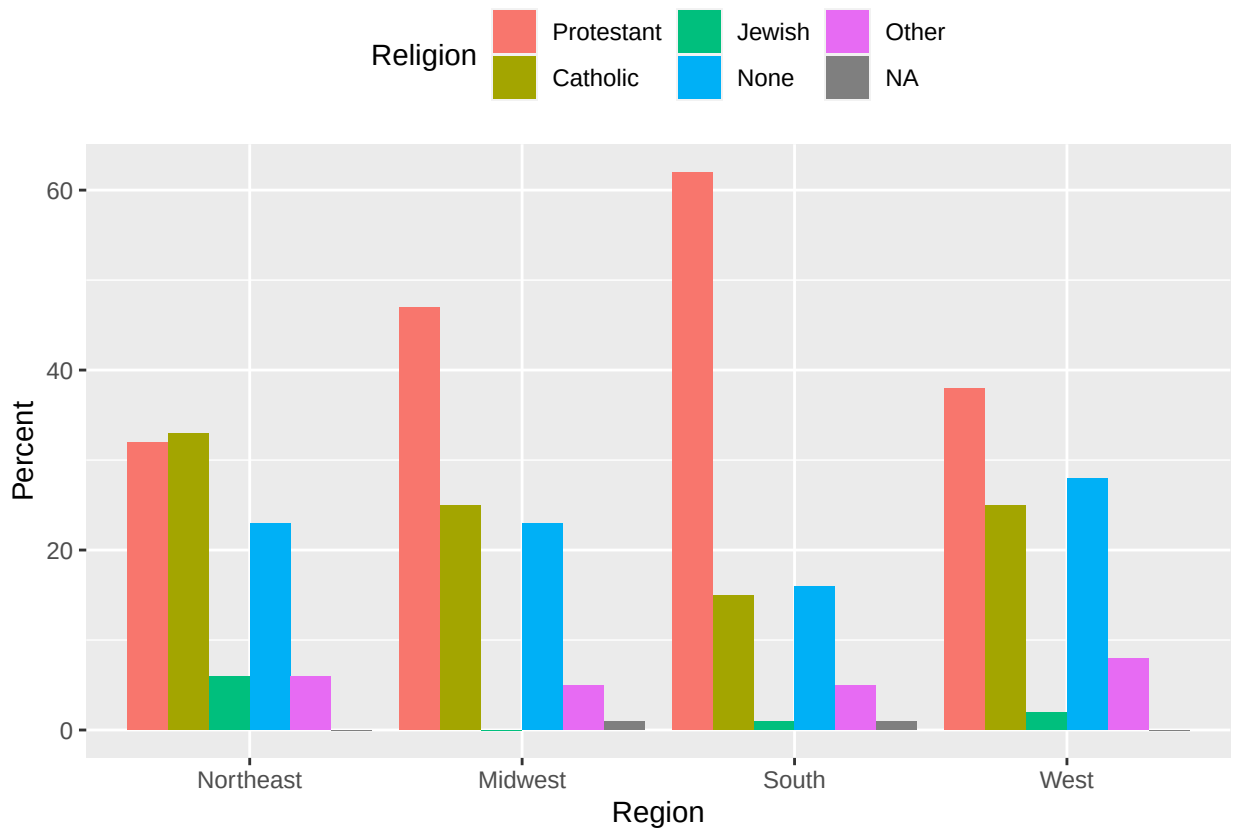

Utlizaremos **dodge2** em vez de **dodge** pois os dados já estão com as proporções computadas.

```
p <- ggplot(rel_by_region,
            aes(x = bigregion, y = pct, fill = religion) )

p + geom_col( position = 'dodge2') +
    labs(x = 'Region', y = 'Percent', fill = 'Religion') +
    theme(legend.position = 'top')
```

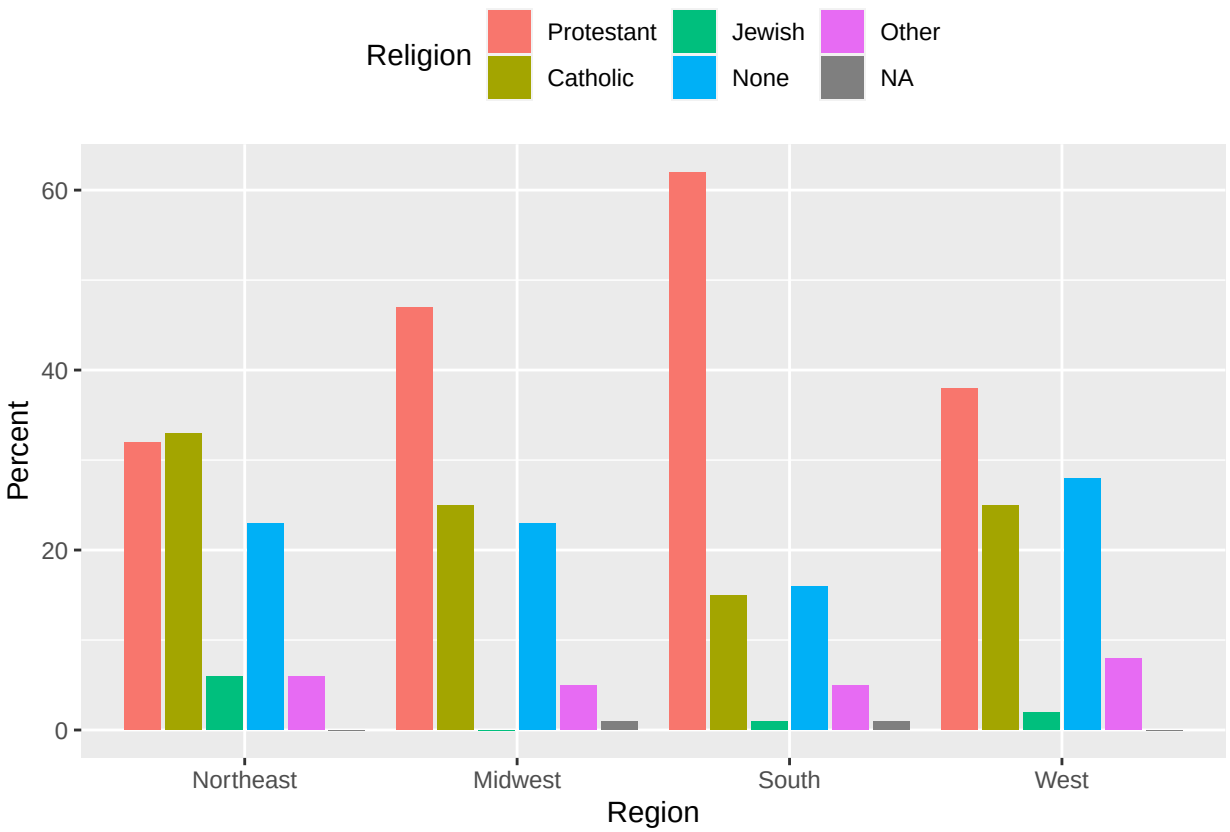

Ainda sim existem várias barras uma ao lado da outra,uma alternativa é deitar o gráfico de barras através do **coord_flip()**.

```
p <- ggplot(rel_by_region,
            aes(x = religion, y = pct, fill = religion) )

p + geom_col( position = 'dodge2') +
    labs(x = NULL, y = 'Percent', fill = 'Religion') +
    guides(fill = FALSE) +
    coord_flip() +
    facet_grid(~ bigregion)
```

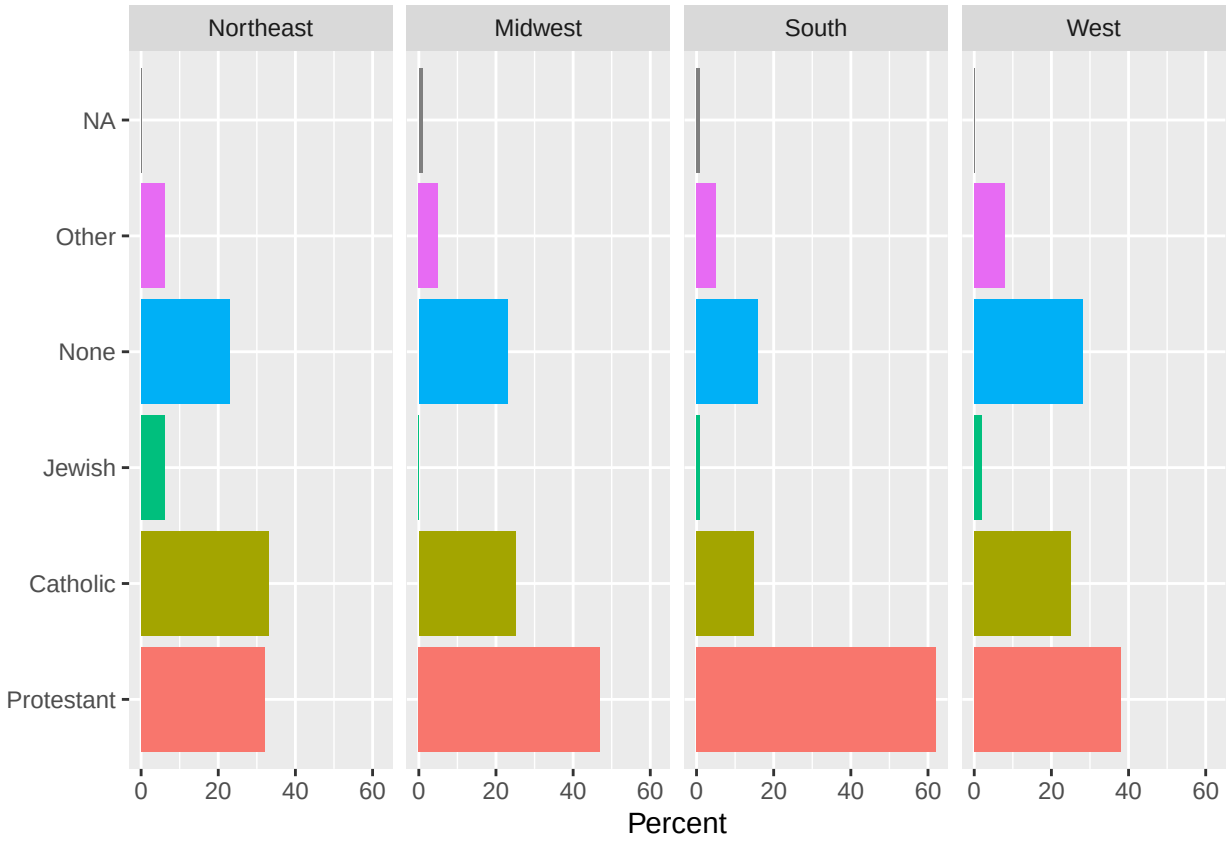

Variáveis Contínuas agrupadas por Categoria ou Grupo

Utilizaremos o dataset *organdata* descrito neste site

Podemos alternativamente ao **head()**,utilizar a função **sample_n()** para coletar 10 linhas aleatoriamente dos dados. Observe que também selecionamos as primeiras 6 colunas.

```
organdata %>%
    select(1:6) %>%
    sample_n(size = 10)
```

```
## # A tibble: 10 x 6
##    country       year       donors    pop pop_dens   gdp
##    <chr>         <date>      <dbl>  <int>    <dbl> <int>
##  1 Sweden        1991-01-01   16.4   8617     1.92 19000
##  2 Austria       1997-01-01   19.5   7968     9.50 24364
##  3 Ireland       1994-01-01   20.3   3590     5.11 15990
##  4 Belgium       NA            NA     NA       NA    NA
##  5 Belgium       1994-01-01   22.8  10116     30.6  20732
##  6 Belgium       2000-01-01   25.6  10251     31.0  25991
##  7 Spain         1992-01-01   21.7  39011     7.71 14331
##  8 Finland       1993-01-01   19.6   5066     1.50 17082
##  9 United States 1992-01-01   17.6 256514     2.66 24411
## 10 Netherlands   1994-01-01   13.1  15383     37.0  20768
```

Vamos plotar a taxa de doação de órgãos por milhão de população, donors, pelo tempo para começar a analisar os dados.

```
p <- ggplot(data = organdata,
            mapping = aes(x = year, y = donors))

p + geom_point()
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

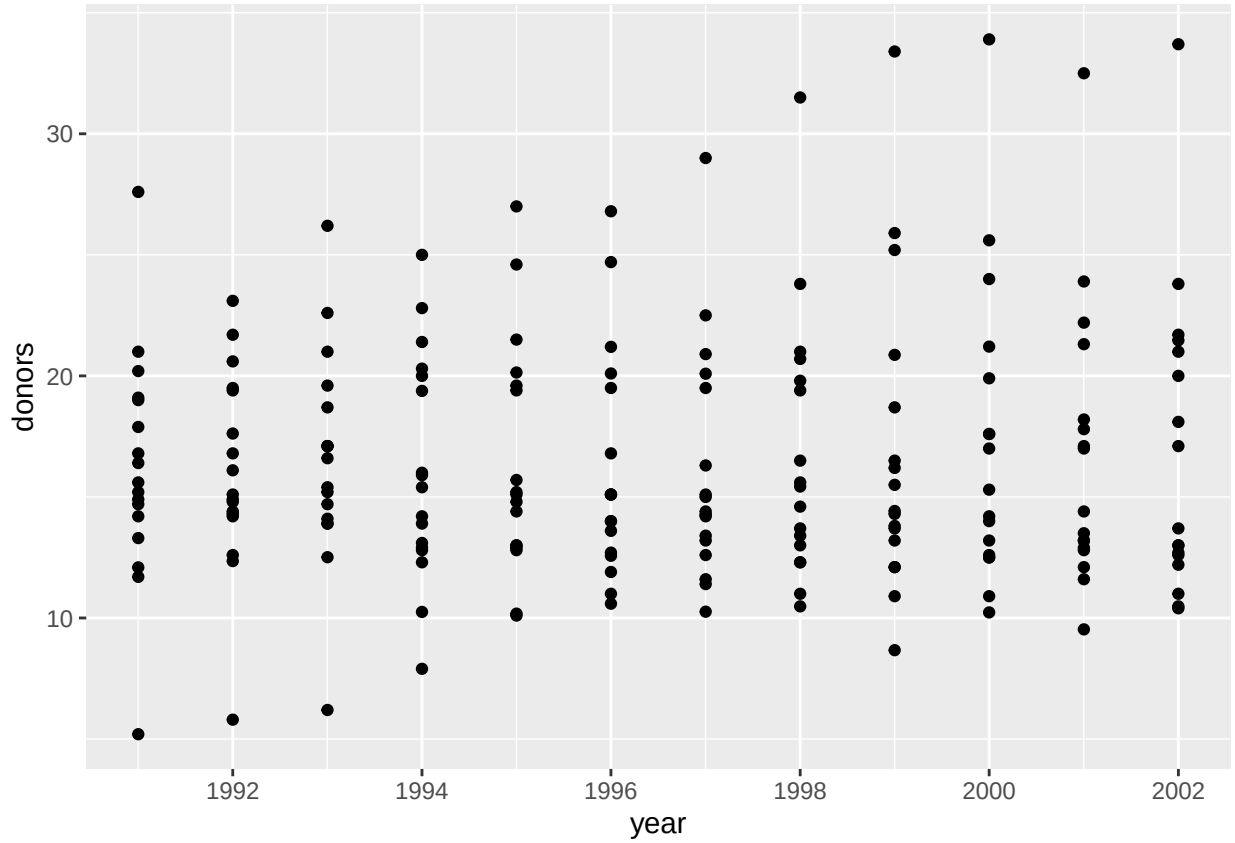

Não muito informativo por enquanto. Podemos plotar a série histórica da taxa de doação de cada país utilizando **geom_line()**:

```
p <- ggplot(data = organdata,
            mapping = aes(x = year, y = donors))

p + geom_line(aes(group = country)) +
  facet_wrap(~country) +
  theme(axis.text.x = element_text(size=6))
```

```
## Warning: Removed 34 row(s) containing missing values (geom_path).
```

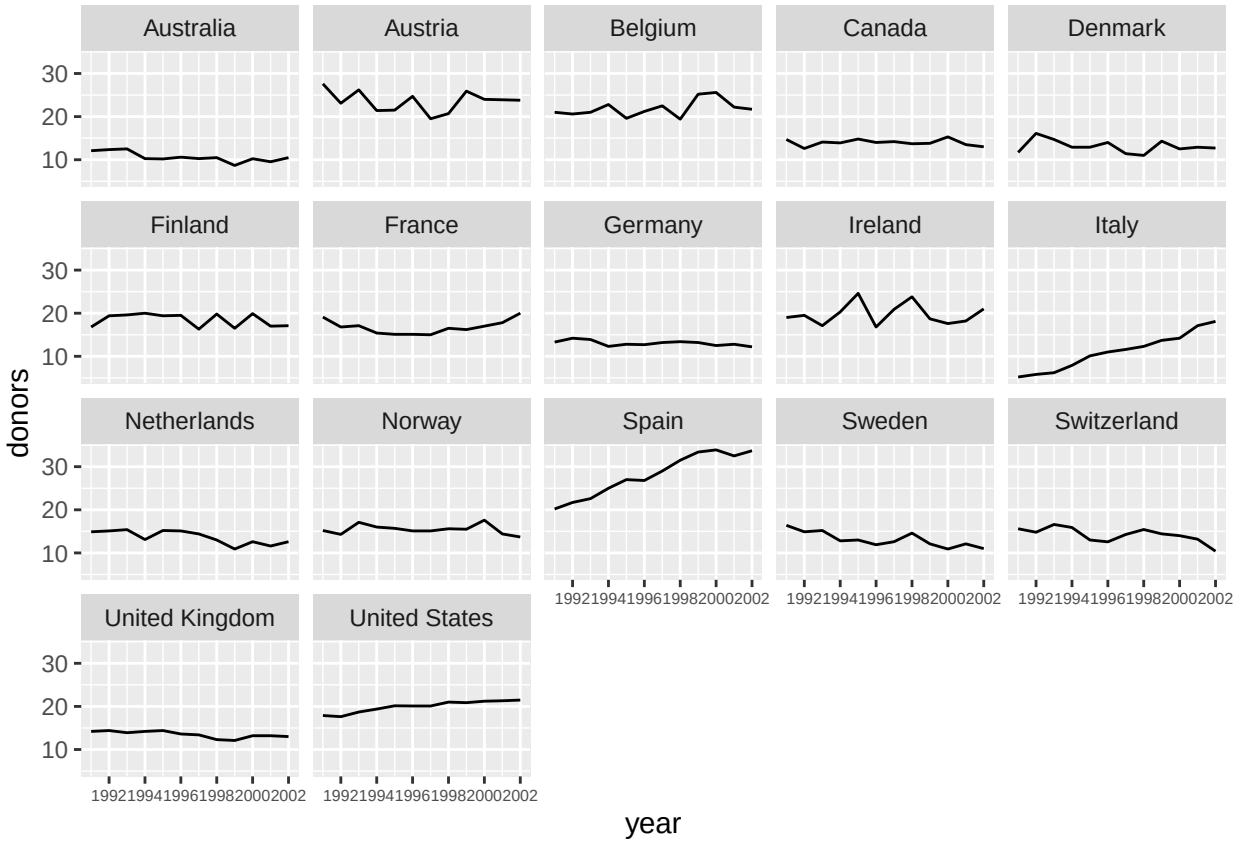

Focando agora não no tempo mas na variação da taxa de doação, plotaremos o boxplot de taxa de doação por país:

```
p <- ggplot(data = organdata,
            mapping = aes(x = country, y = donors))

p + geom_boxplot() +
  theme(axis.text.x = element_text(angle = 45))
```

```
## Warning: Removed 34 rows containing non-finite values (stat_boxplot).
```

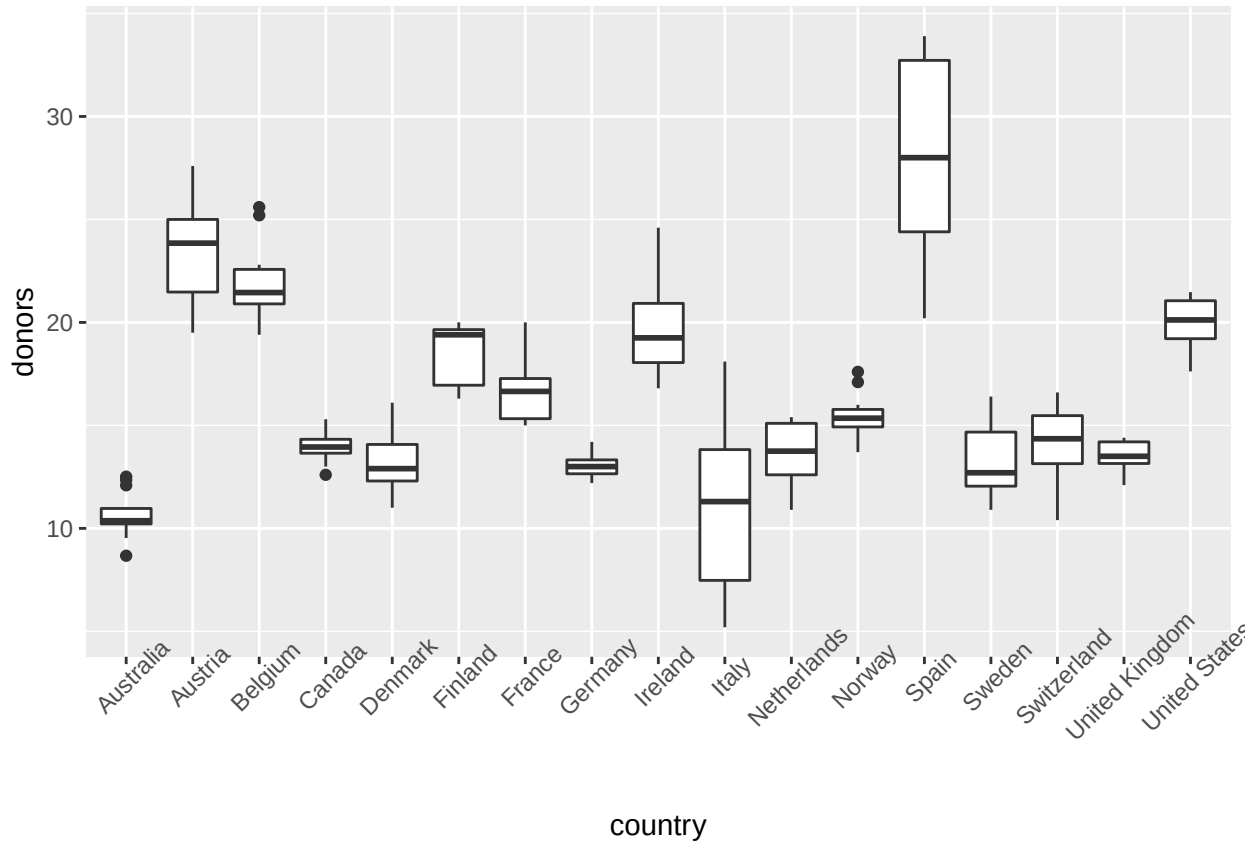

Observe que os países se sobrepoem, uma alternativa é deitar o gráfico usando **coord_flip()**:

```
p <- ggplot(data = organdata,
            mapping = aes(x = country, y = donors))

p + geom_boxplot() +
    coord_flip()
```

```
## Warning: Removed 34 rows containing non-finite values (stat_boxplot).
```

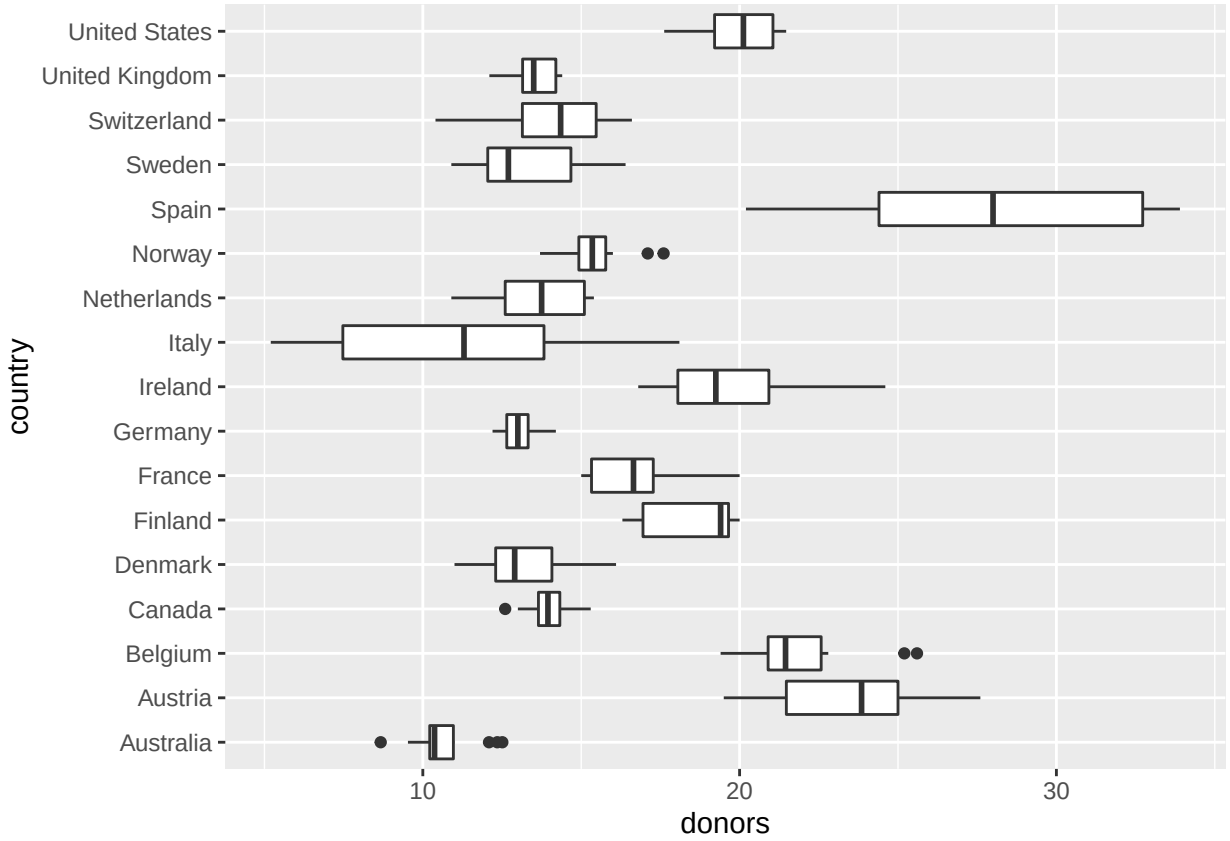

Mesmo mais legível, ele parece a priori pouco informativo, porque os países estão por ordem alfabética. Podemos reordená-los pela taxa de doações médias através da função **reorder()**

```
p <- ggplot(data = organdata,
            mapping = aes(x = reorder(country,
                                      donors,
                                      na.rm = TRUE),
                          y = donors) )

p + geom_boxplot() +
    labs(x = NULL) +
    coord_flip()
```

```
## Warning: Removed 34 rows containing non-finite values (stat_boxplot).
```

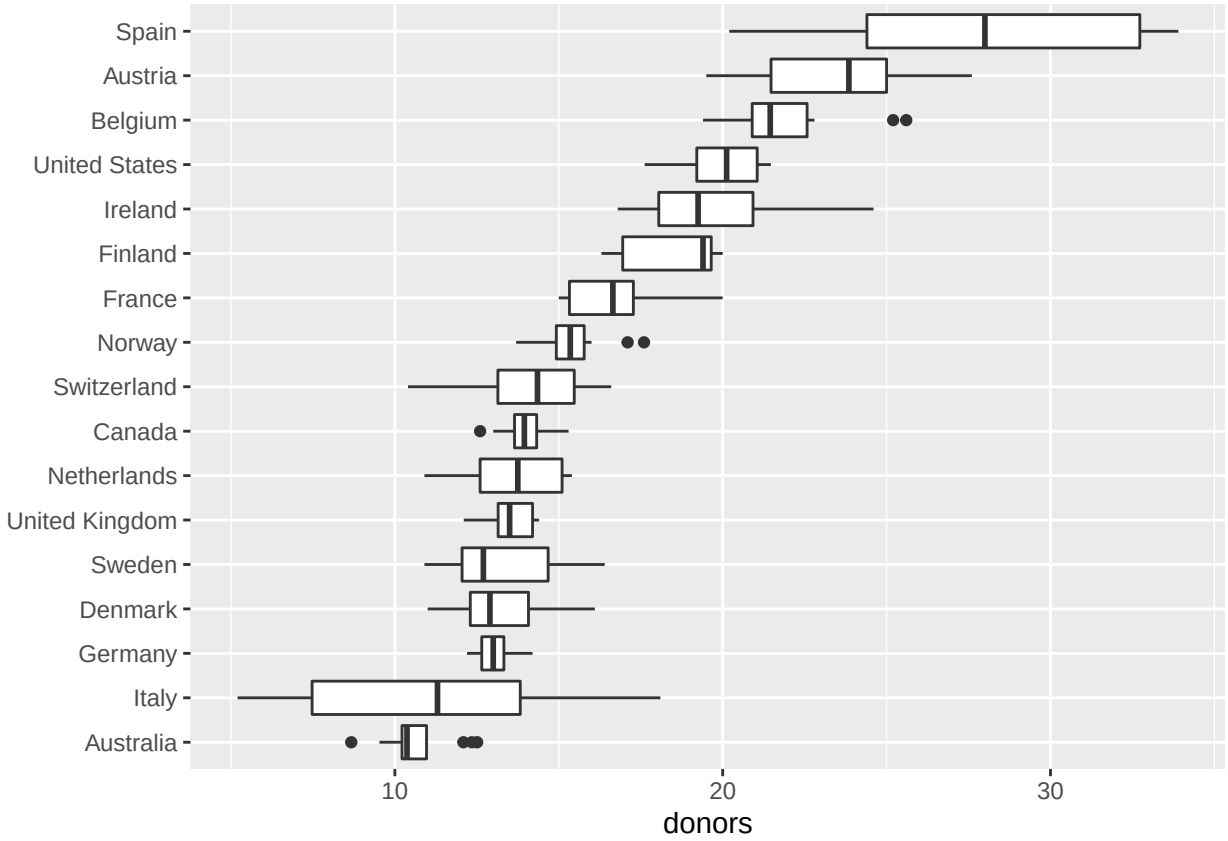

Podemos alternativamente fazer o **Violin plot** através da função **geom_violin()**

```
p <- ggplot(data = organdata,
            mapping = aes(x = reorder(country,
                                      donors,
                                      na.rm = TRUE),
                          y = donors) )

p + geom_violin() +
    labs(x = NULL) +
    coord_flip()
```

```
## Warning: Removed 34 rows containing non-finite values (stat_ydensity).
```

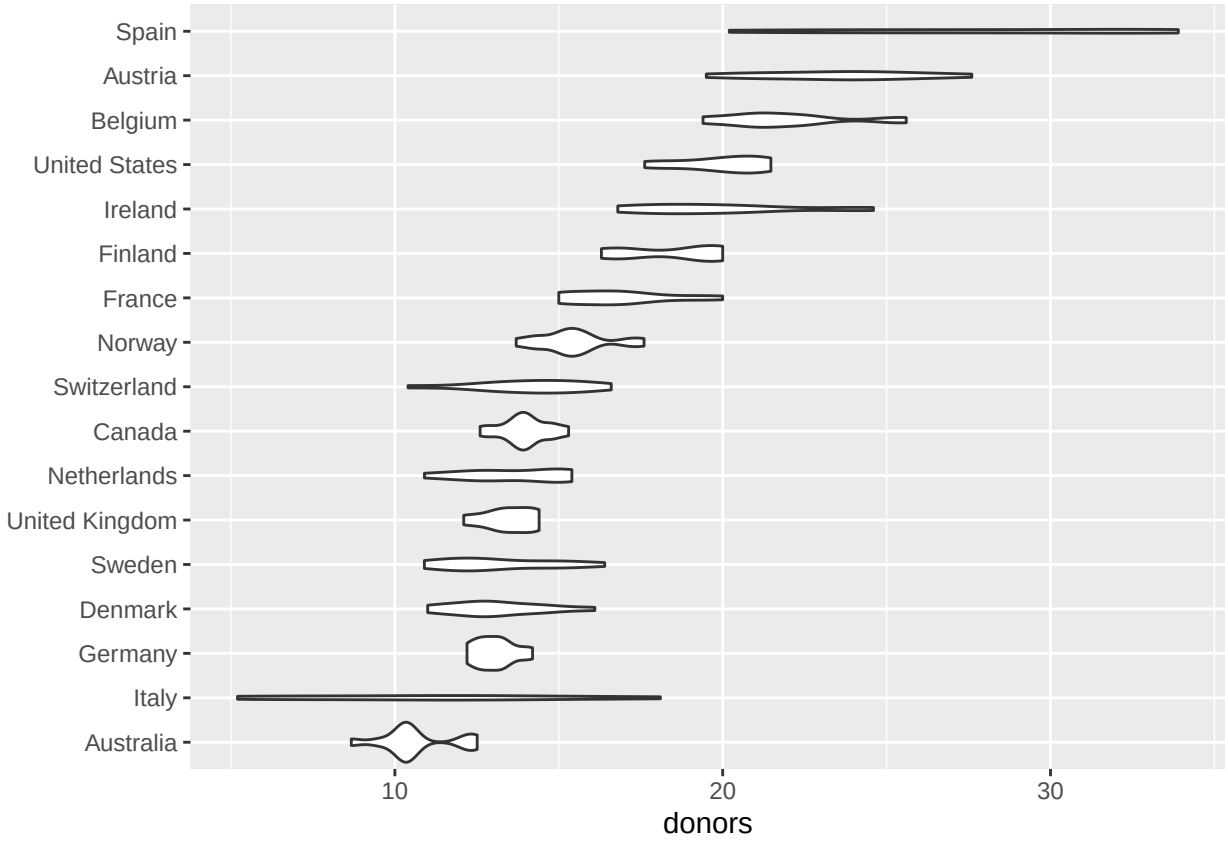

Podemos também colorir os boxplots de acordo com a variável categórica **world**:

```
p <- ggplot(data = organdata,
            mapping = aes(x = reorder(country, donors, na.rm = TRUE),
                          y = donors,
                          fill = world) )

p + geom_boxplot() +
    labs(x = NULL) +
    coord_flip() +
    theme(legend.position = 'top')
```

```
## Warning: Removed 34 rows containing non-finite values (stat_boxplot).
```

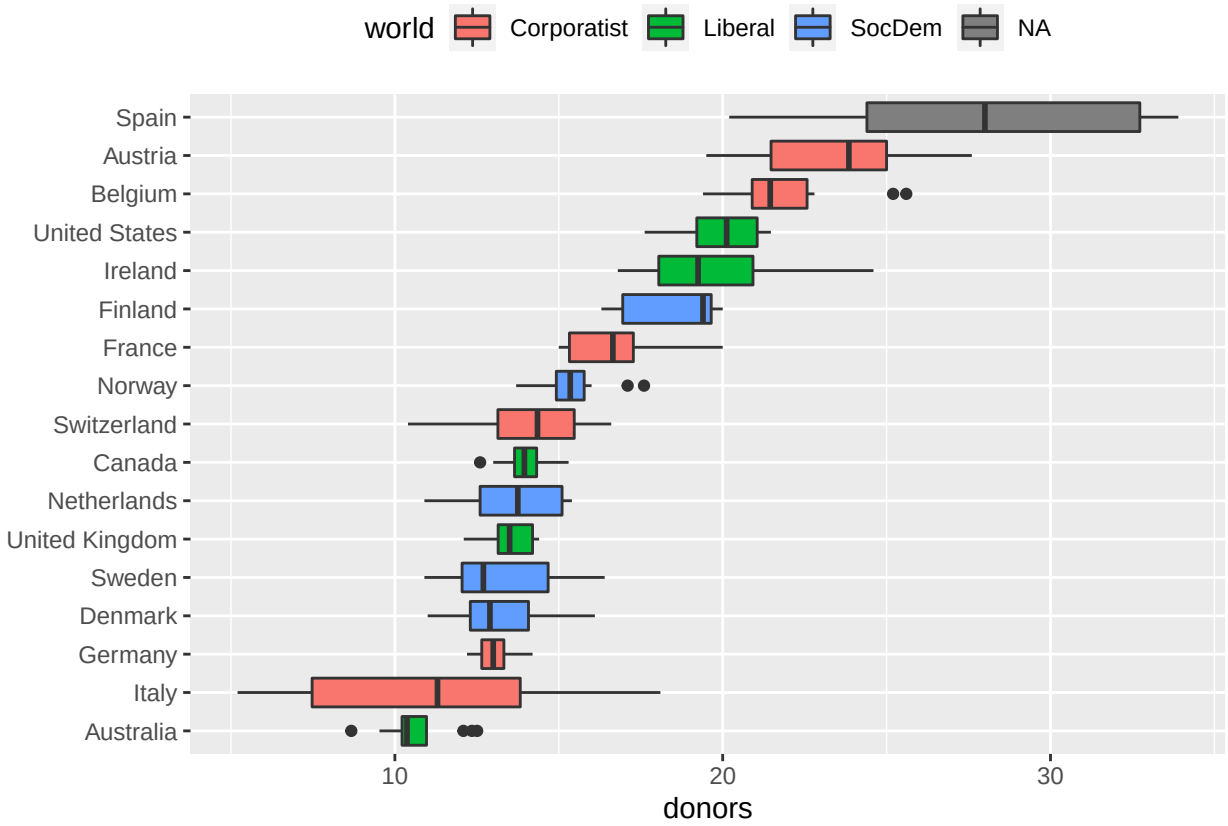

Colocando variáveis categóricas na vertical para comparar as distribuições é um bom recurso para resumir muitos pontos.Entretanto quando a quantidade de pontos por categoria é relativamente pequena, podemos simplismente plotar as observações.

Vamos utilizar a função **geom_point()** em vez de **geom_boxplot()** fazendo os devidos ajustes de parâmetros:

```
p <- ggplot(data = organdata,
            mapping = aes(x = reorder(country, donors, na.rm = TRUE),
                          y = donors,
                          color = world) )

p + geom_point() +
    labs(x = NULL) +
    coord_flip() +
    theme(legend.position = 'top')
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

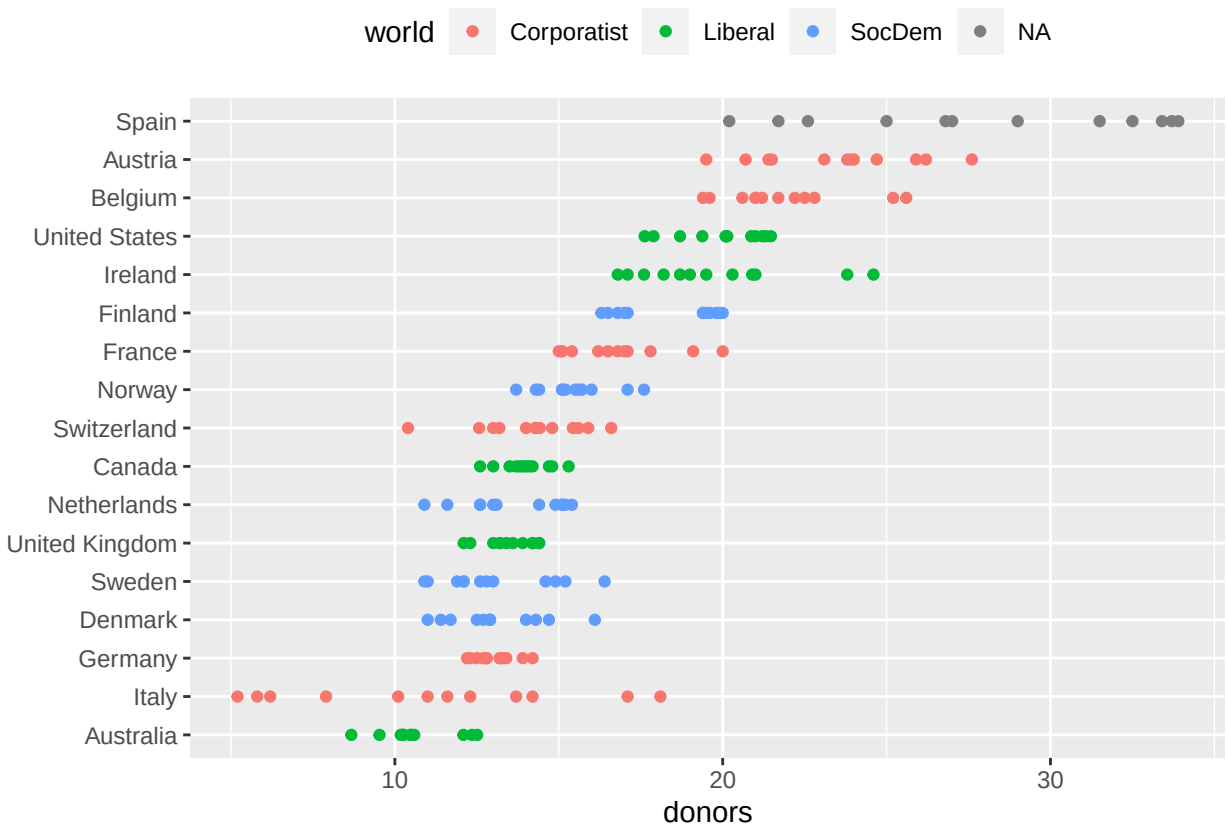

Perceba que desta forma, existe sobreposição de observações, nestes casos podemos perturbar os dados para evitar esta sobreposição através da função **geom_jitter()**:

```
p <- ggplot(data = organdata,
            mapping = aes(x = reorder(country, donors, na.rm = TRUE),
                          y = donors,
                          color = world) )

p + geom_jitter() +
    labs(x = NULL) +
    coord_flip() +
    theme(legend.position = 'top')
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

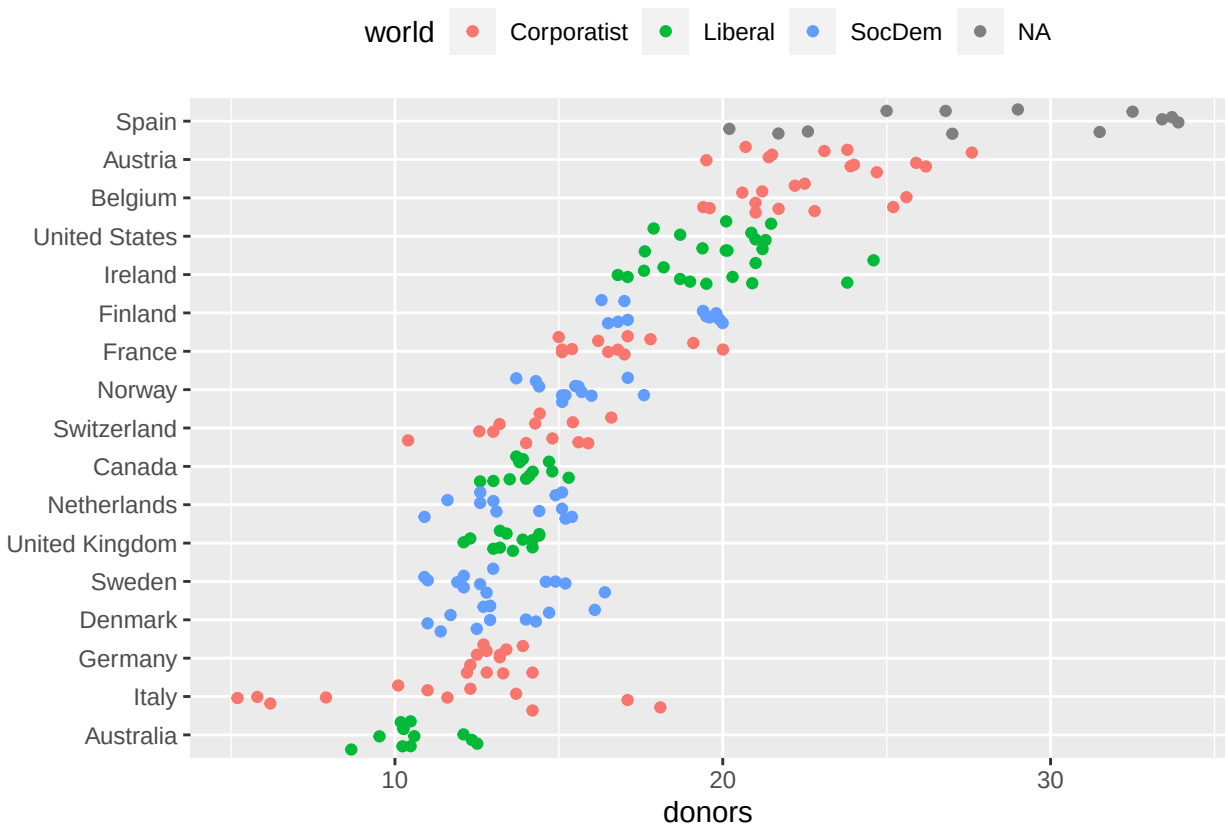

Podemos regular o grau de pertubação de dados com o parâmetros **width** e **height**:

```
p <- ggplot(data = organdata,
            mapping = aes(x = reorder(country, donors, na.rm = TRUE),
                          y = donors,
                          color = world) )

p + geom_jitter(position = position_jitter(width = 0,
                                           height = 0.5) ) +
    labs(x = NULL) +
    coord_flip() +
    theme(legend.position = 'top')
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

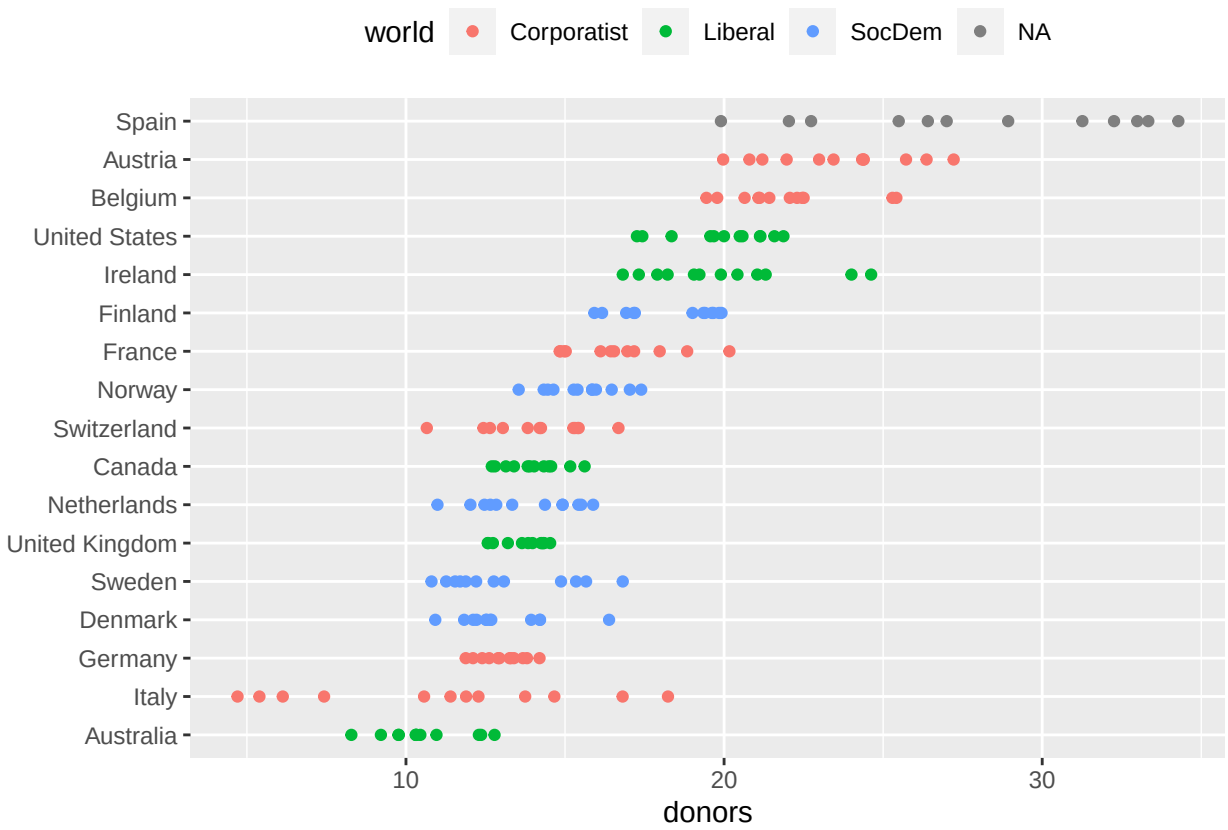

Dado o formato do gráfico, usaremos apenas o **width**, pois o **heigh** altera o eixo y (não esqueça que deitamos o gráfico), ou seja, altera a distribuição das observações.

```
p <- ggplot(data = organdata,
            mapping = aes(x = reorder(country, donors, na.rm = TRUE),
                          y = donors,
                          color = world) )

p + geom_jitter(position = position_jitter(width = 0.15) ) +
    labs(x = NULL) +
    coord_flip() +
    theme(legend.position = 'top')
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

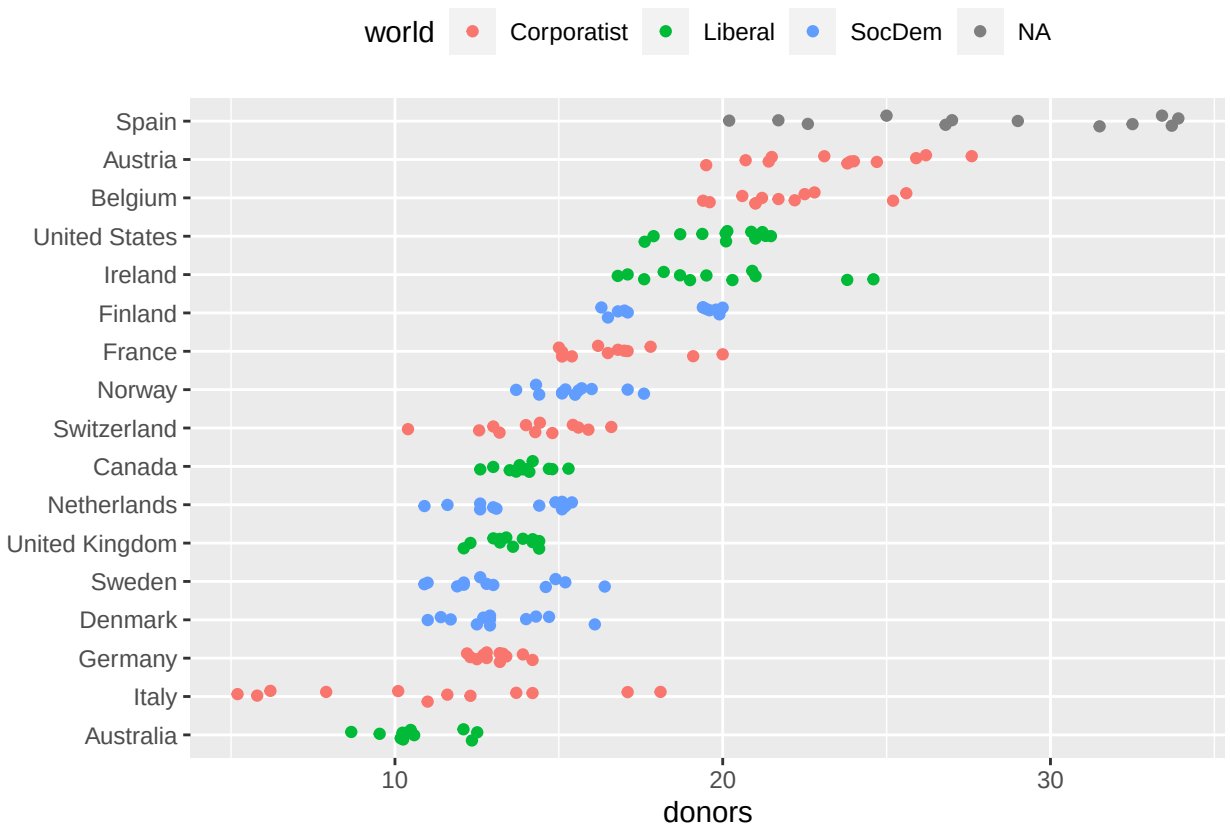

Quando queremos resumir uma variável categórica com apenas um valor por catergoria, como a taxa média de doações por país, podemos usar o **Cleverland plot**.

Vamos fazer um pipeline para agregar e resumir nosso dataframe, podemos escolher manualmente as variáveis e usar repetidamente as funções de resumo **mean()** e **std()**:

```
by_country <- organdata %>%
  group_by(consent_law, country) %>%
  summarize(donors_mean = mean(donors, na.rm = TRUE),
            donors_sd = sd(donors, na.rm = TRUE),
            gdp_mean = mean(gdp, na.rm = TRUE),
            health_mean = mean(health, na.rm = TRUE),
            roads_mean = mean(roads, na.rm = TRUE),
            cerebvas_mean = mean(cerebvas, na.rm = TRUE))
```

```
## `summarise()` has grouped output by 'consent_law'. You can override using the `.groups` argument.
```

```
by_country
```

```
## # A tibble: 17 x 8
## # Groups:   consent_law [2]
##    consent_law country     donors_mean donors_sd gdp_mean health_mean roads_mean
##    <chr>       <chr>             <dbl>     <dbl>    <dbl>       <dbl>      <dbl>
##  1 Informed    Australia          10.6     1.14    22179.       1958.      105.
##  2 Informed    Canada             14.0     0.751   23711.       2272.      109.
##  3 Informed    Denmark            13.1     1.47    23722.       2054.      102.
```

```
##  4 Informed    Germany            13.0     0.611   22163.       2349.      113.
##  5 Informed    Ireland            19.8     2.48    20824.       1480.      118.
##  6 Informed    Netherlands        13.7     1.55    23013.       1993.       76.1
##  7 Informed    United Kin~        13.5     0.775   21359.       1561.       67.9
##  8 Informed    United Sta~        20.0     1.33    29212.       3988.      155.
##  9 Presumed    Austria            23.5     2.42    23876.       1875.      150.
## 10 Presumed    Belgium            21.9     1.94    22500.       1958.      155.
## 11 Presumed    Finland            18.4     1.53    21019.       1615.       93.6
## 12 Presumed    France             16.8     1.60    22603.       2160.      156.
## 13 Presumed    Italy              11.1     4.28    21554.       1757       122.
## 14 Presumed    Norway             15.4     1.11    26448.       2217.       70.0
## 15 Presumed    Spain              28.1     4.96    16933        1289.      161.
## 16 Presumed    Sweden             13.1     1.75    22415.       1951.       72.3
## 17 Presumed    Switzerland        14.2     1.71    27233        2776.       96.4
## # ... with 1 more variable: cerebvas_mean <dbl>
```

Ou alternativamente podemos fazer esta tarefa iterando através de recursos de programação funcional do R:

```
by_country <- organdata %>%
  group_by(consent_law, country) %>%
    summarize_if(is.numeric, funs(mean, sd), na.rm = TRUE) %>%
    ungroup()
```

```
## Warning: `funs()` was deprecated in dplyr 0.8.0.
## Please use a list of either functions or lambdas:
##
##   # Simple named list:
##   list(mean = mean, median = median)
##
##   # Auto named with `tibble::lst()`:
##   tibble::lst(mean, median)
##
##   # Using lambdas
##   list(~ mean(., trim = .2), ~ median(., na.rm = TRUE))
```

```
by_country
```

```
## # A tibble: 17 x 28
##    consent_law country  donors_mean pop_mean pop_dens_mean gdp_mean gdp_lag_mean
##    <chr>       <chr>          <dbl>    <dbl>         <dbl>    <dbl>        <dbl>
##  1 Informed    Austral~        10.6   18318.         0.237   22179.       21779.
##  2 Informed    Canada          14.0   29608.         0.297   23711.       23353.
##  3 Informed    Denmark         13.1    5257.        12.2     23722.       23275
##  4 Informed    Germany         13.0   80255.        22.5     22163.       21938.
##  5 Informed    Ireland         19.8    3674.         5.23    20824.       20154.
##  6 Informed    Netherl~        13.7   15548.        37.4     23013.       22554.
##  7 Informed    United ~        13.5   58187.        24.0     21359.       20962.
##  8 Informed    United ~        20.0  269330.         2.80    29212.       28699.
##  9 Presumed    Austria         23.5    7927.         9.45    23876.       23415.
## 10 Presumed    Belgium         21.9   10153.        30.7     22500.       22096.
## 11 Presumed    Finland         18.4    5112.         1.51    21019.       20763
## 12 Presumed    France          16.8   58056.        10.5     22603.       22211.
## 13 Presumed    Italy           11.1   57360.        19.0     21554.       21195.
```

```
## 14 Presumed    Norway          15.4    4386.         1.35    26448.       25769.
## 15 Presumed    Spain           28.1   39666.         7.84    16933        16584.
## 16 Presumed    Sweden          13.1    8789.         1.95    22415.       22094
## 17 Presumed    Switzer~        14.2    7037.        17.0     27233        26931.
## # ... with 21 more variables: health_mean <dbl>, health_lag_mean <dbl>,
## #   pubhealth_mean <dbl>, roads_mean <dbl>, cerebvas_mean <dbl>,
## #   assault_mean <dbl>, external_mean <dbl>, txp_pop_mean <dbl>,
## #   donors_sd <dbl>, pop_sd <dbl>, pop_dens_sd <dbl>, gdp_sd <dbl>,
## #   gdp_lag_sd <dbl>, health_sd <dbl>, health_lag_sd <dbl>, pubhealth_sd <dbl>,
## #   roads_sd <dbl>, cerebvas_sd <dbl>, assault_sd <dbl>, external_sd <dbl>,
## #   txp_pop_sd <dbl>
```

Com os dado resumidos por país, podemos fazer um **Cleveland dotplot** com os pontos coloridos conforme a variável categórica **consent_law**.

```
p <- ggplot(data = by_country,
            mapping = aes(x = donors_mean,
                          y = reorder(country, donors_mean),
                          color = consent_law))
p + geom_point(size=3) +
    labs(x = "Donor Procurement Rate",
         y = "", color = "Consent Law") +
    theme(legend.position="top")
```

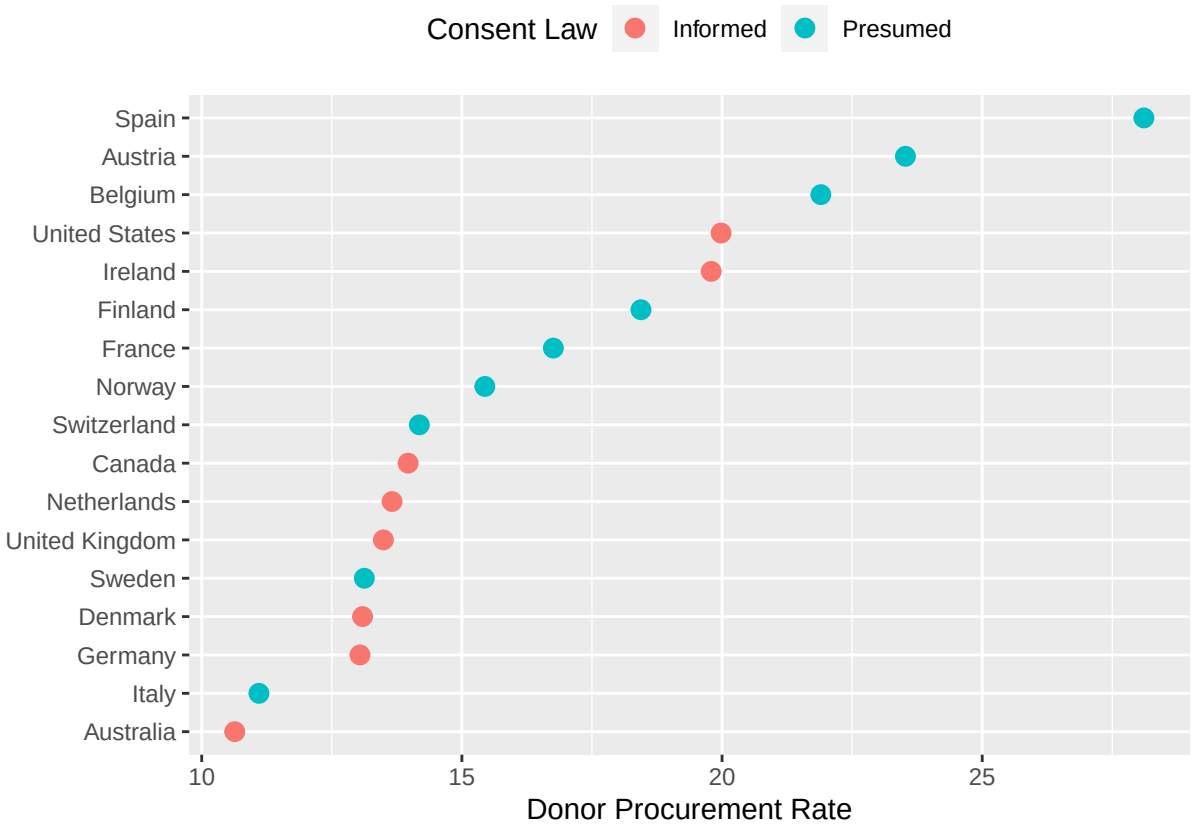

Alternativamente podemos plotar separadamente pela categoria **consent_law** em vez de colorir. Colocaremos os gráficos empilhados, **ncol = 1**, para melhor compará-los dado que são da mesma escala.

```
p <- ggplot(data = by_country,
            mapping = aes(x = donors_mean,
                          y = reorder(country, donors_mean)))

p + geom_point(size=3) +
    facet_wrap(~ consent_law, ncol = 1) +
    labs(x= "Donor Procurement Rate",
         y= "")
```

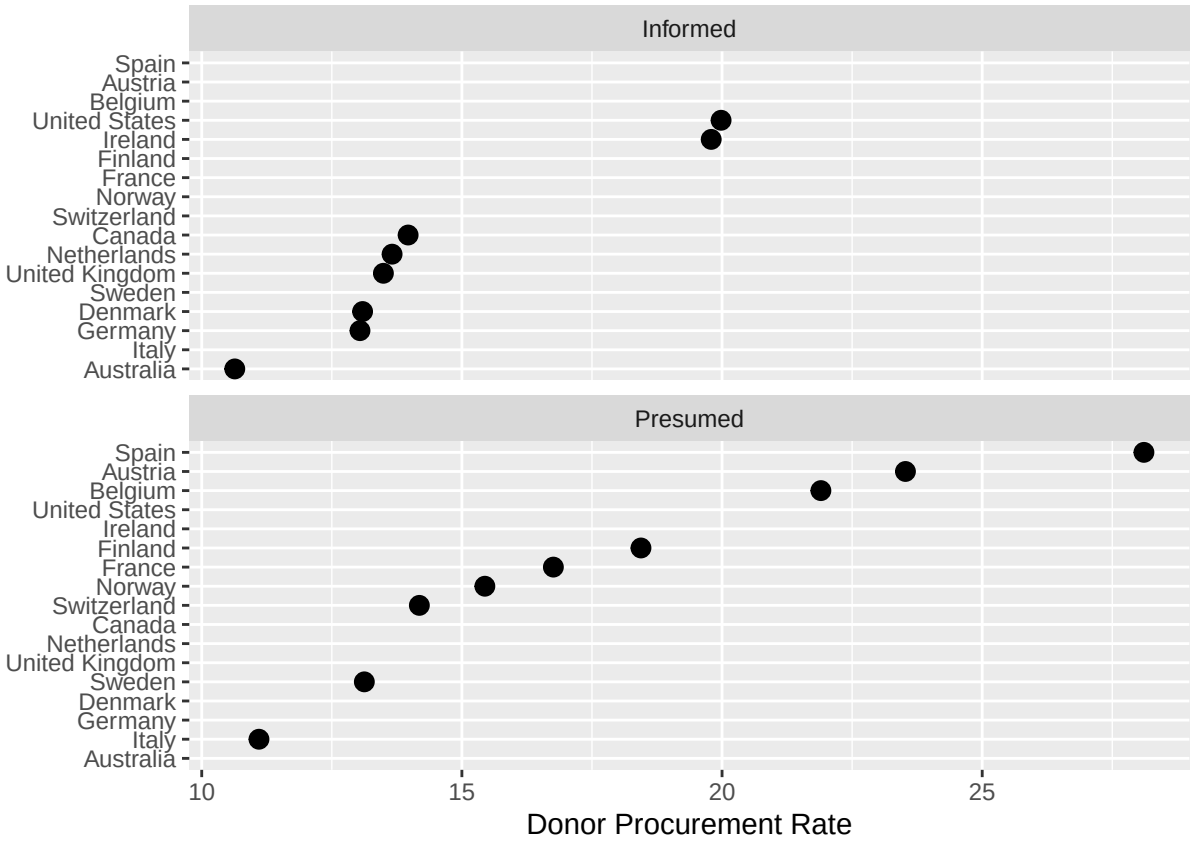

Note que pelo eixo y ser categórico, ele vai plotar o nome todos os países nos 2 plots, então para evitar isso colocaremos **scales = "free_y"**.

```
p <- ggplot(data = by_country,
            mapping = aes(x = donors_mean,
                          y = reorder(country, donors_mean)))

p + geom_point(size=3) +
    facet_wrap(~ consent_law, scales = "free_y", ncol = 1) +
    labs(x= "Donor Procurement Rate",
         y= "")
```

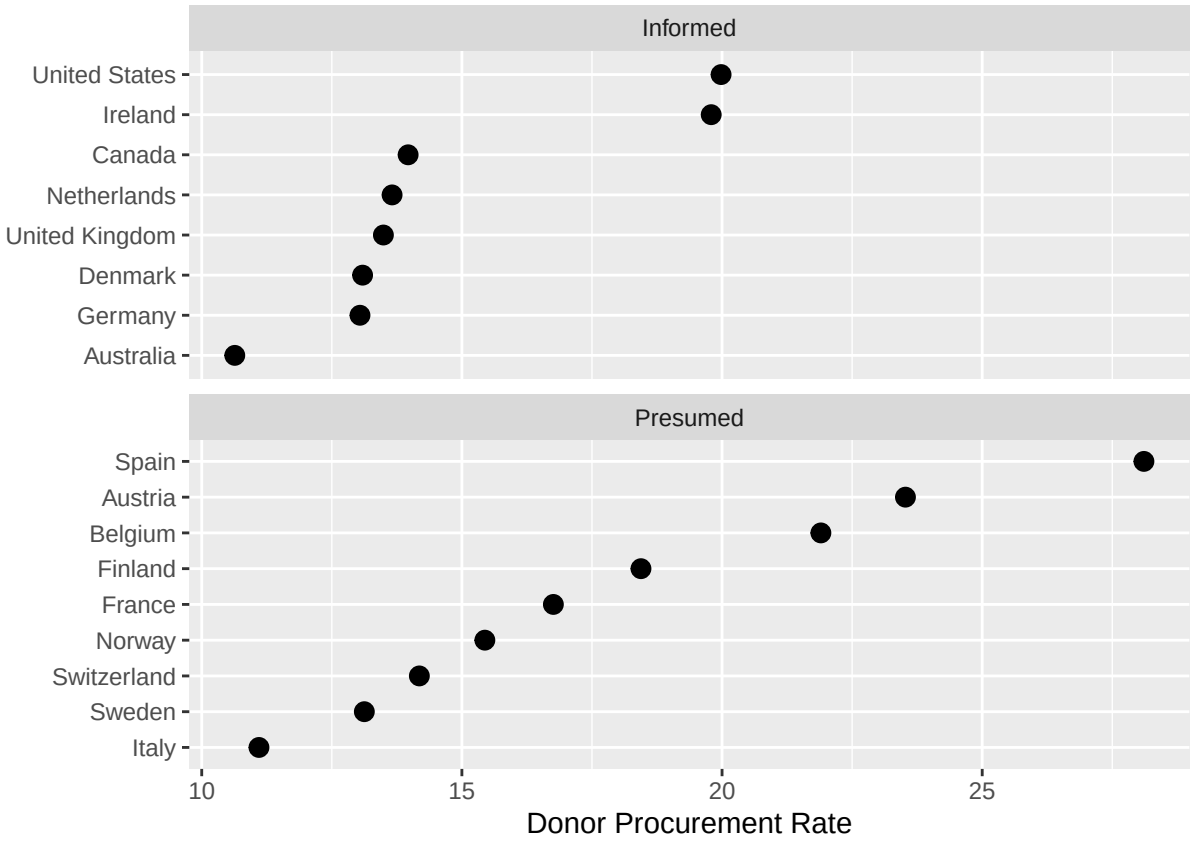

Cleverland plots é um ótimo recurso de resumir resultados de dados que possuem erros de range. Para extender este tipo de plot e incluir medidas de variância ou erro utilizamos o **geom_pointrange**.

Este precisa do range em que se encontram os dados, **ymin** e **ymax**:

```
p <- ggplot(data = by_country,
            mapping = aes(x = reorder(country,donors_mean),
                          y = donors_mean))

p + geom_pointrange(mapping = aes(ymin = donors_mean - donors_sd,
                                  ymax = donors_mean + donors_sd)) +
  labs(x= "", y= "Donor Procurement Rate") +
  coord_flip()
```

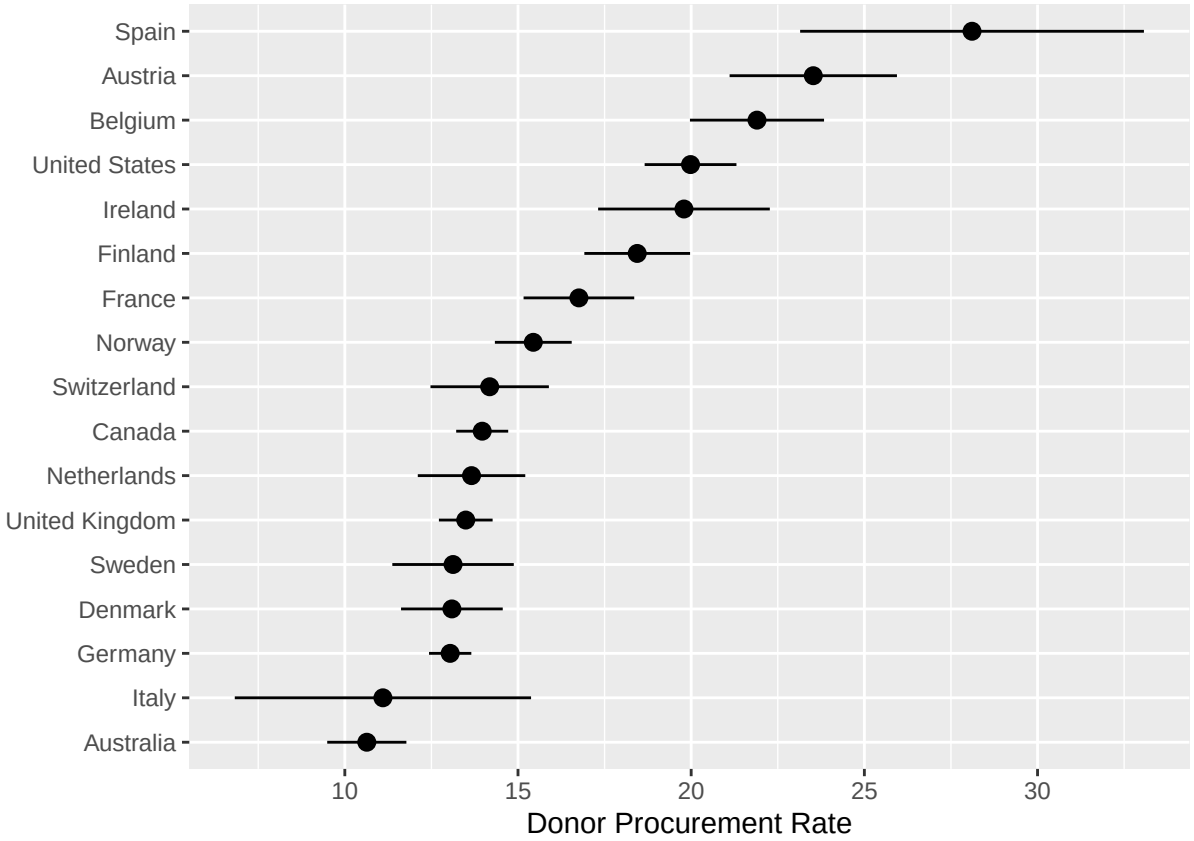

Adicionando texto

Pode ser útil as vezes plotar os labels dos pontos diretamente, podemos fazer isso através da função **geom_text()**

```
p <- ggplot(data = by_country,
            mapping = aes(x = roads_mean,
                          y = donors_mean))

p + geom_point() +
  geom_text(mapping = aes(label = country))
```

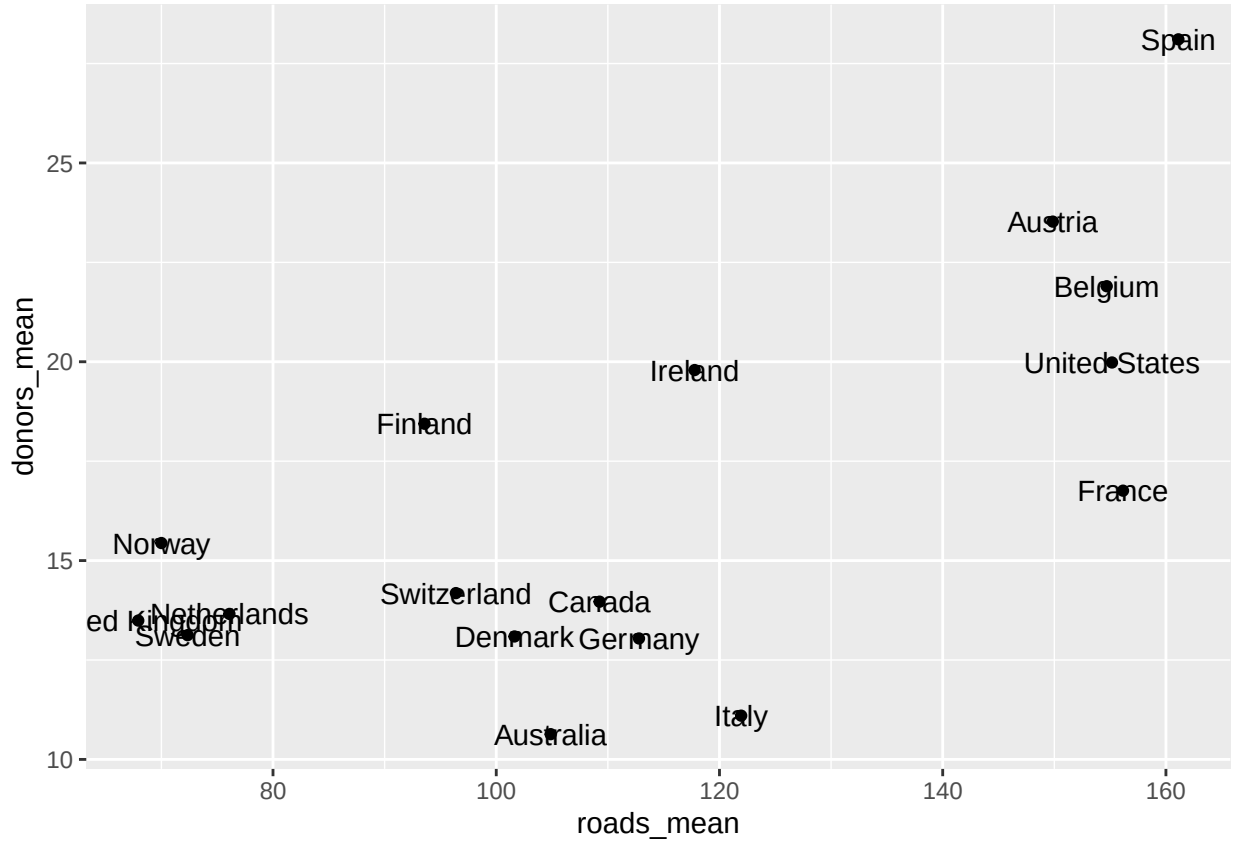

Como estamos utilizando o mesmo **mapping** para os pontos e labels, eles ficam sobrepostos.

Para corrigir isso podemos retirar os pontos e manter os labels:

```
p <- ggplot(data = by_country,
            mapping = aes(x = roads_mean,
                          y = donors_mean))

p + geom_text(mapping = aes(label = country))
```

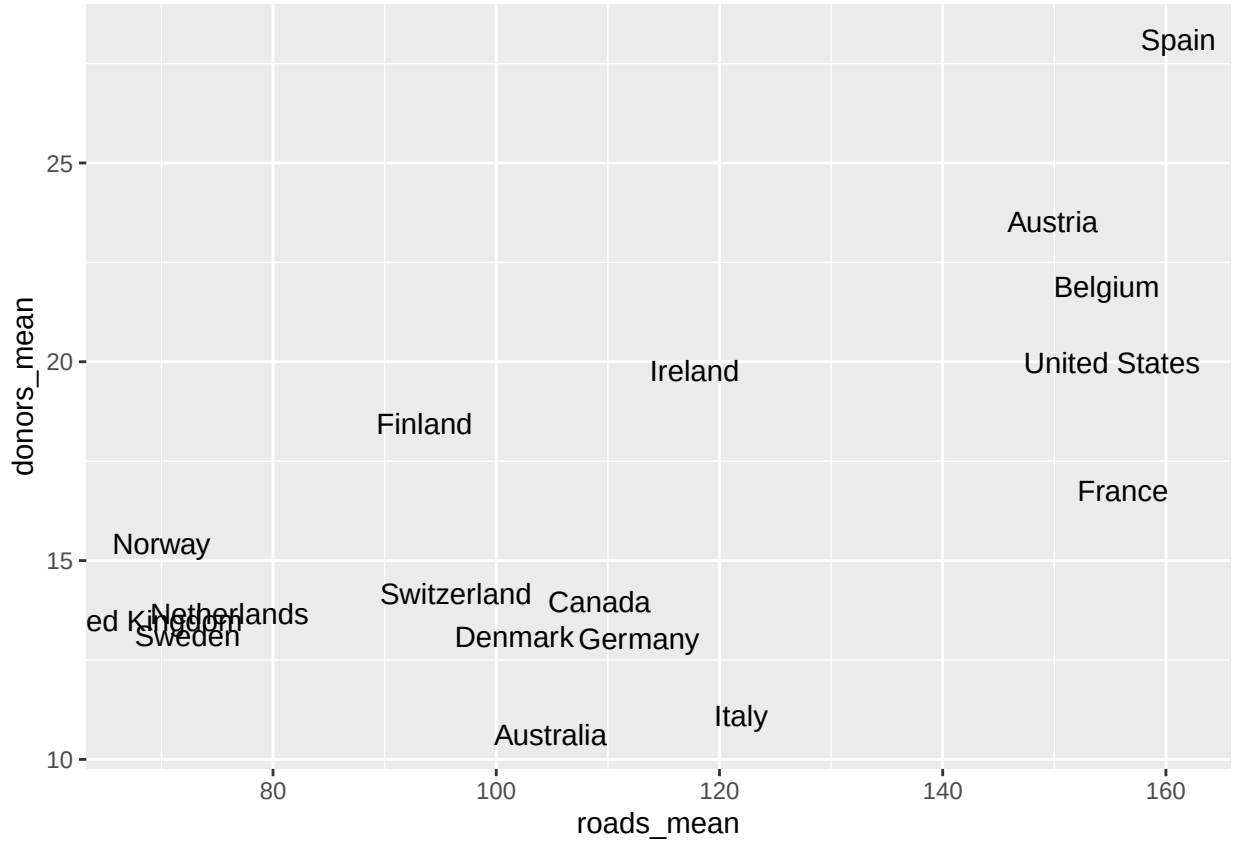

Ou alternativamente é ajustar o label, utilizando **hjust = 0** para deslocar para a esquerda e **hjust = 1** para a direita.

```
p <- ggplot(data = by_country,
            mapping = aes(x = roads_mean,
                          y = donors_mean))

p + geom_point() +
  geom_text(mapping = aes(label = country),
            hjust = 0)
```

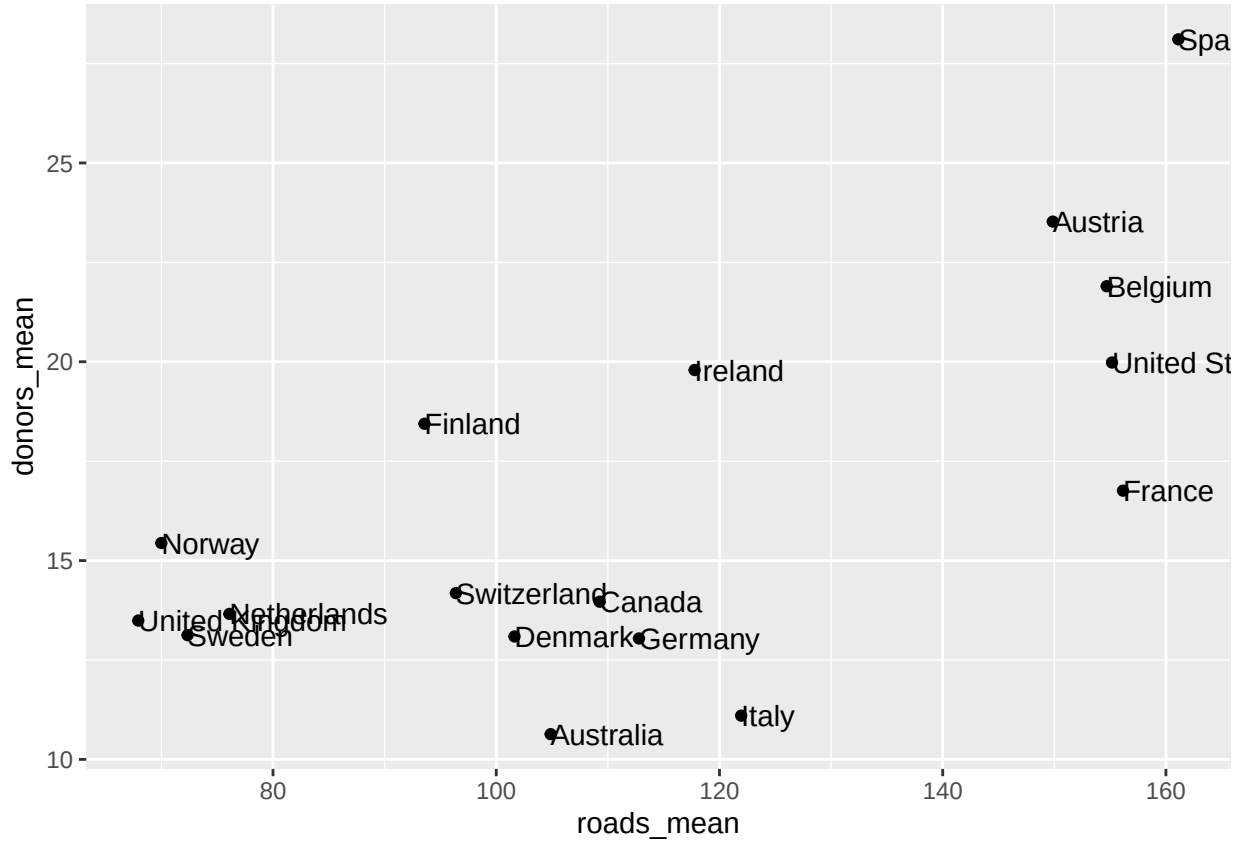

Perceba que por mais que modifiquemos o ajuste do label, não parece uma abordagem robusta. Em vez de usar **geom_text()** vamos usar as funções **geom_text_repel()** e **geom_label_repel()** da biblioteca **ggrepel**.

```
library(ggrepel)
```

```
## Warning: package 'ggrepel' was built under R version 4.0.5
```

Vamos utilizar o dataset **elections_historic** descrito neste site

```
elections_historic %>% select(2:7)
```

```
## # A tibble: 49 x 6
##     year winner                win_party ec_pct popular_pct popular_margin
##    <int> <chr>                 <chr>      <dbl>       <dbl>          <dbl>
##  1  1824 John Quincy Adams     D.-R.      0.322       0.309        -0.104
##  2  1828 Andrew Jackson        Dem.       0.682       0.559         0.122
##  3  1832 Andrew Jackson        Dem.       0.766       0.547         0.178
##  4  1836 Martin Van Buren      Dem.       0.578       0.508         0.142
##  5  1840 William Henry Harrison Whig      0.796       0.529         0.0605
##  6  1844 James Polk            Dem.       0.618       0.495         0.0145
##  7  1848 Zachary Taylor        Whig       0.562       0.473         0.0479
##  8  1852 Franklin Pierce       Dem.       0.858       0.508         0.0695
##  9  1856 James Buchanan        Dem.       0.588       0.453         0.122
## 10  1860 Abraham Lincoln       Rep.       0.594       0.396         0.101
## # ... with 39 more rows
```

A figura a seguir plota cada eleição presidencial Americana desde 1824, primeiro ano que foi computado o voto popular. Em que os eixos são a parcela de votos no vencedor e a parcela de votos do vencedor que são populares.

Estando interessados em certas presidências, vamos adicionar labels aos pontos. Porém para evitar sobreposição, como discutido anteriormente, vamos utilizar a função **geom_text_repel()**.

```
p_title <- "Presidential Elections: Popular & Electoral College Margins"
p_subtitle <- "1824-2016"
p_caption <- "Data for 2016 are provisional."

x_label <- "Winner's share of Popular Vote"
y_label <- "Winner's share of Electoral College Votes"


p <- ggplot(elections_historic, aes(x = popular_pct,
                                    y = ec_pct,
                                    label = winner_label))

p + geom_hline(yintercept = 0.5,
               size = 1.4,
               color = "gray80") +
    geom_vline(xintercept = 0.5,
               size = 1.4,
               color = "gray80") +
    geom_point() +
    geom_text_repel() +
    scale_x_continuous(labels = scales::percent) +
    scale_y_continuous(labels = scales::percent) +
    labs(x = x_label,
         y = y_label,
         title = p_title,
         subtitle = p_subtitle,
         caption = p_caption)
```

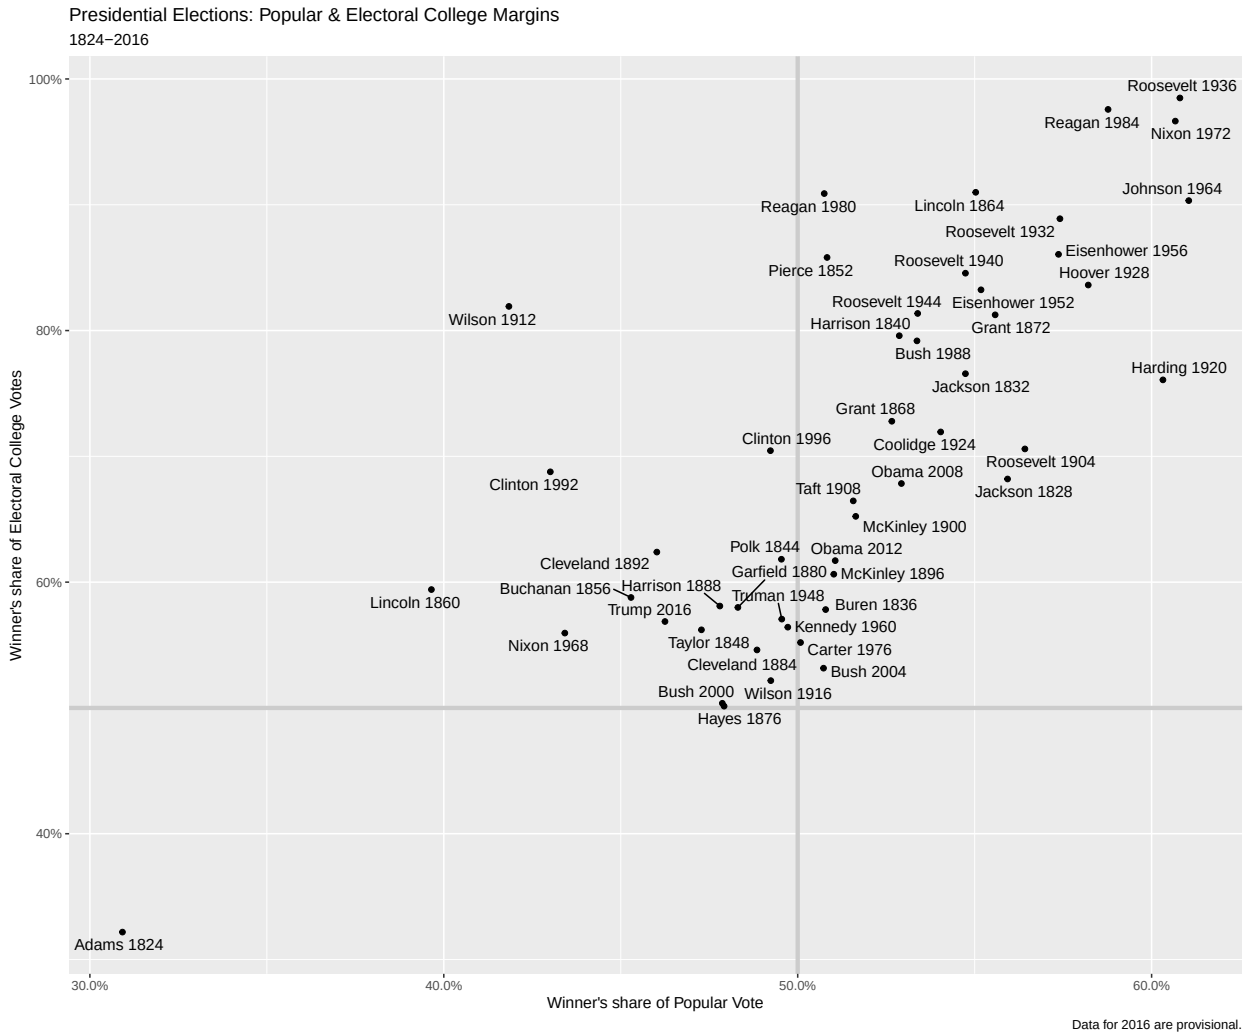

Como os dados dos eixos estão em proporção, de 0 a 1, utilizamos a função **scale_x_continuous()** e **scale_y_continuous()** para transformá-los em porcentagens.

Adicionaremos retas que marcam 50% de votos no vencedor e 50% de votos do vencedor que são populares para melhor analisar o distanciamento de cada ponto destas retas.

Texto condicional

Perceba que as vezes não é uma boa ideia nomear todos os pontos do plot, mas sim escolher alguns de interesse para adicionar seus labels. Podemos fazer isso ainda com as mesmas funções.

Basta que passemos um dataframe apenas com os pontos selecionados para a função **geom_text_repel()** através da ferramenta **subset()**. Como podemos ver a seguir:

```
p <- ggplot(data = by_country,
            mapping = aes(x = gdp_mean,
                          y = health_mean))

p + geom_point() +
    geom_text_repel(data = subset(by_country,
```

```
                                    gdp_mean > 25000),
                    mapping = aes(label = country))
```

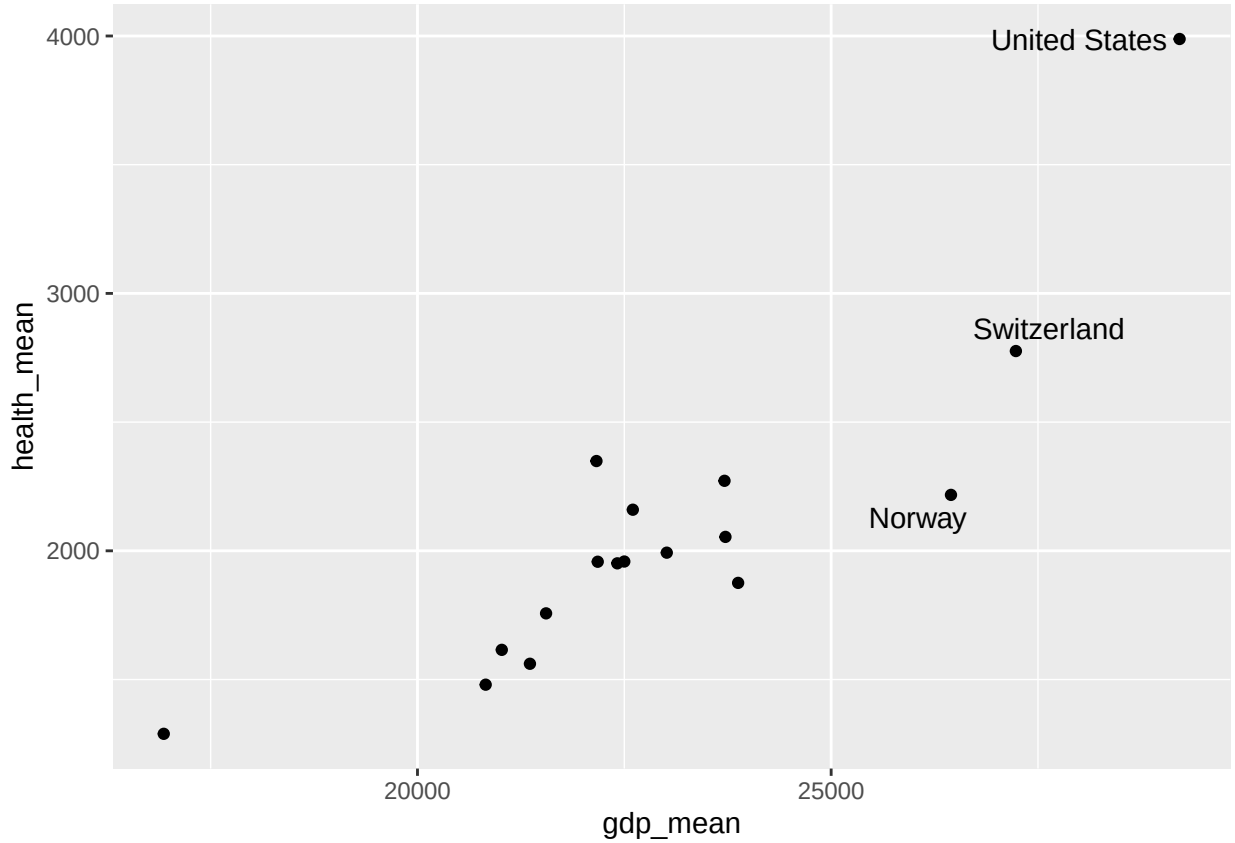

Neste caso utilizamos um critério apenas, para mais critérios é de modo similar:

```
p <- ggplot(data = by_country,
            mapping = aes(x = gdp_mean,
                          y = health_mean))

p + geom_point() +
    geom_text_repel(data = subset(by_country,
                                  gdp_mean > 25000 |
                                    health_mean < 1500 |
                                    country %in% "Belgium"),
                    mapping = aes(label = country))
```

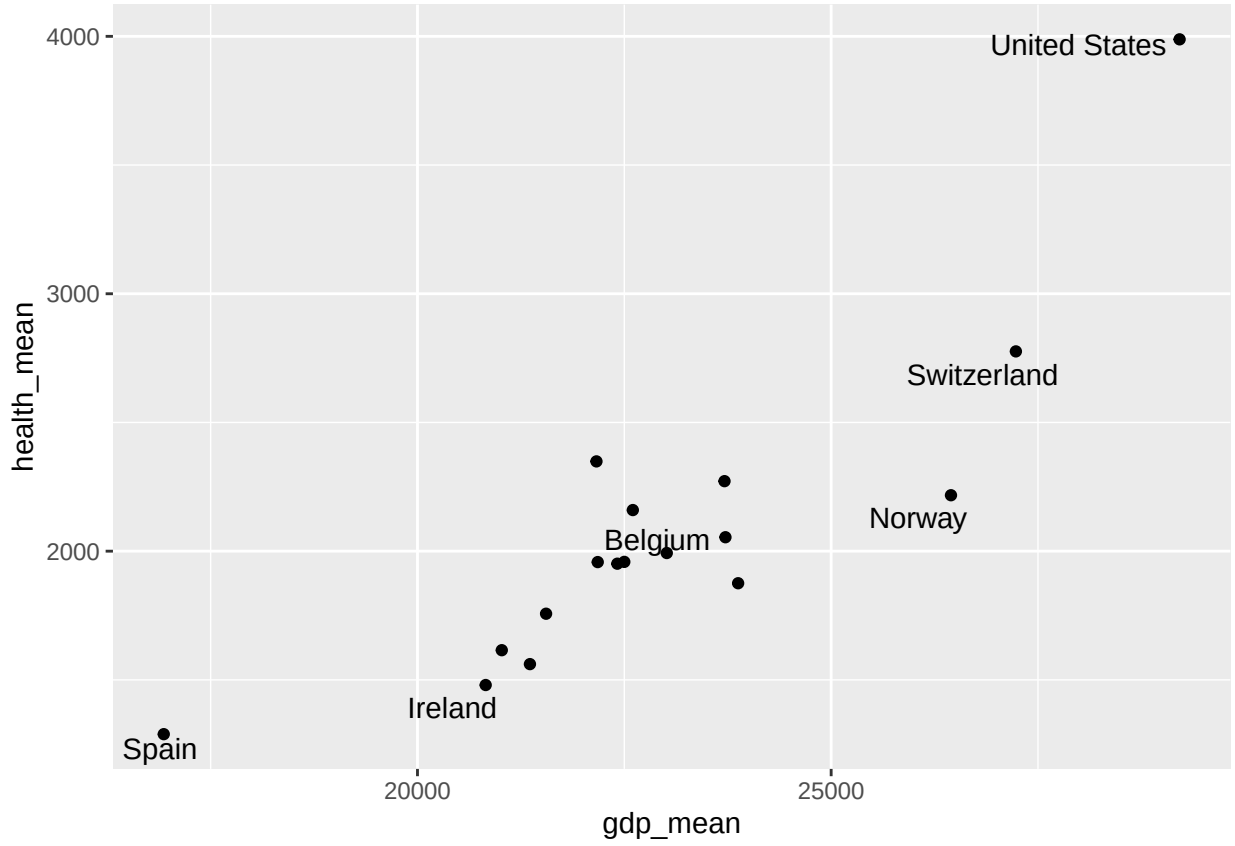

Alternativamente, podemos selecionar pontos específicos criando uma variável auxiliar para essa tarefa, no caso abaixo criamos a coluna **ind**.

```
organdata$ind <- organdata$ccode %in%
  c("Ita", "Spa") & organdata$year > 1998


p <- ggplot(data = organdata,
            mapping = aes(x = roads,
                          y = donors,
                          color = ind))

p + geom_point() +
    geom_text_repel(data = subset(organdata, ind),
                    mapping = aes(label = ccode)) +
    guides(label = FALSE,
           color = FALSE)
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

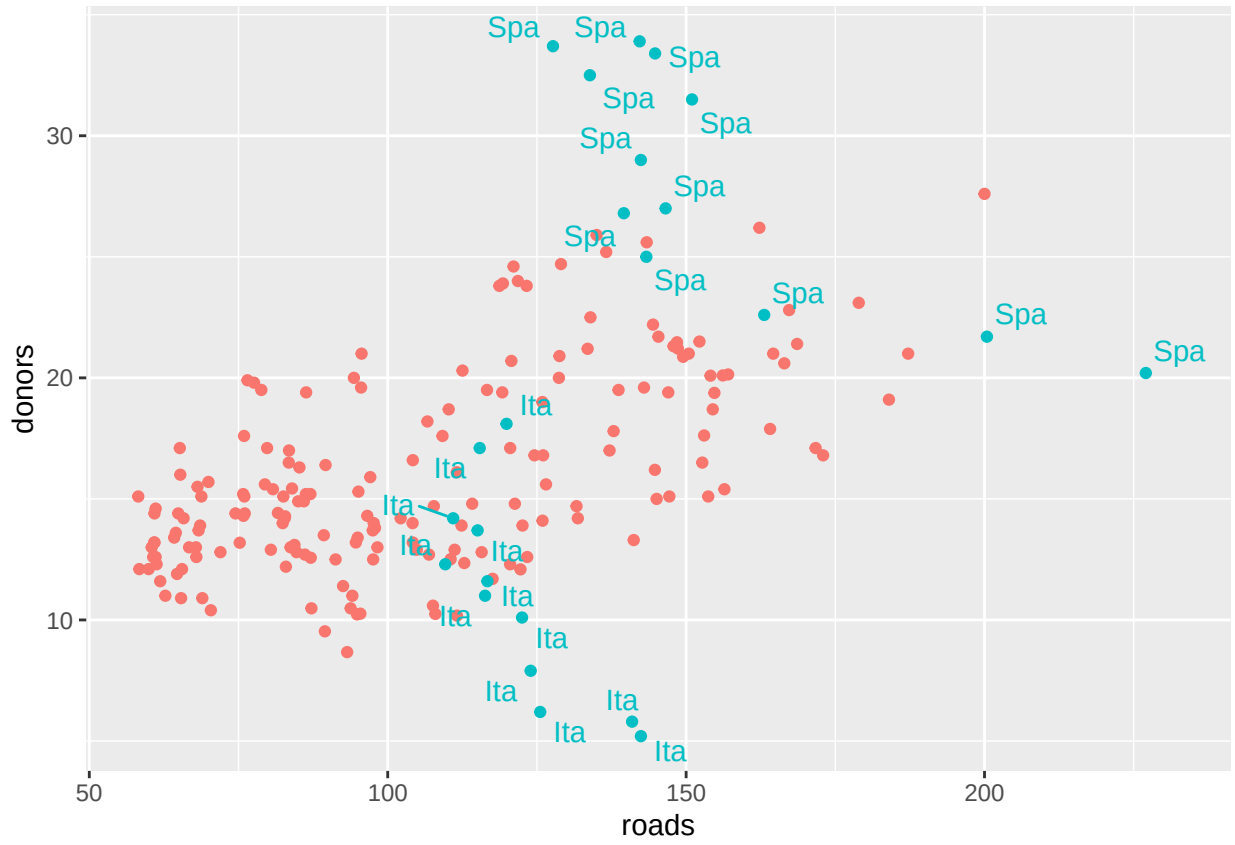

Utilizamos a coluna auxiliar tanto no filtro de labels quanto no parâmetro **color**. Além disso, para suprimir a legenda faz-se uso da função **guides()**.

Escrevendo e desenhando no Gráfico

Por vezes se faz necessário fazer anotações diretamente no gráfico para fazer alguma observação. Utilizaremos a função **annotate()** e diremos para ela utilizar os argumentos da **geom_text()** através do parâmetro **geom**. Como pode-se ver no exemplo a seguir:

```
p <- ggplot(data = organdata,
            mapping = aes(x = roads,
                          y = donors))

p + geom_point() +
  annotate(geom = "text",
           x = 91,
           y = 33,
           label = "A surprisingly high \n recovery rate.",
           hjust = 0)
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

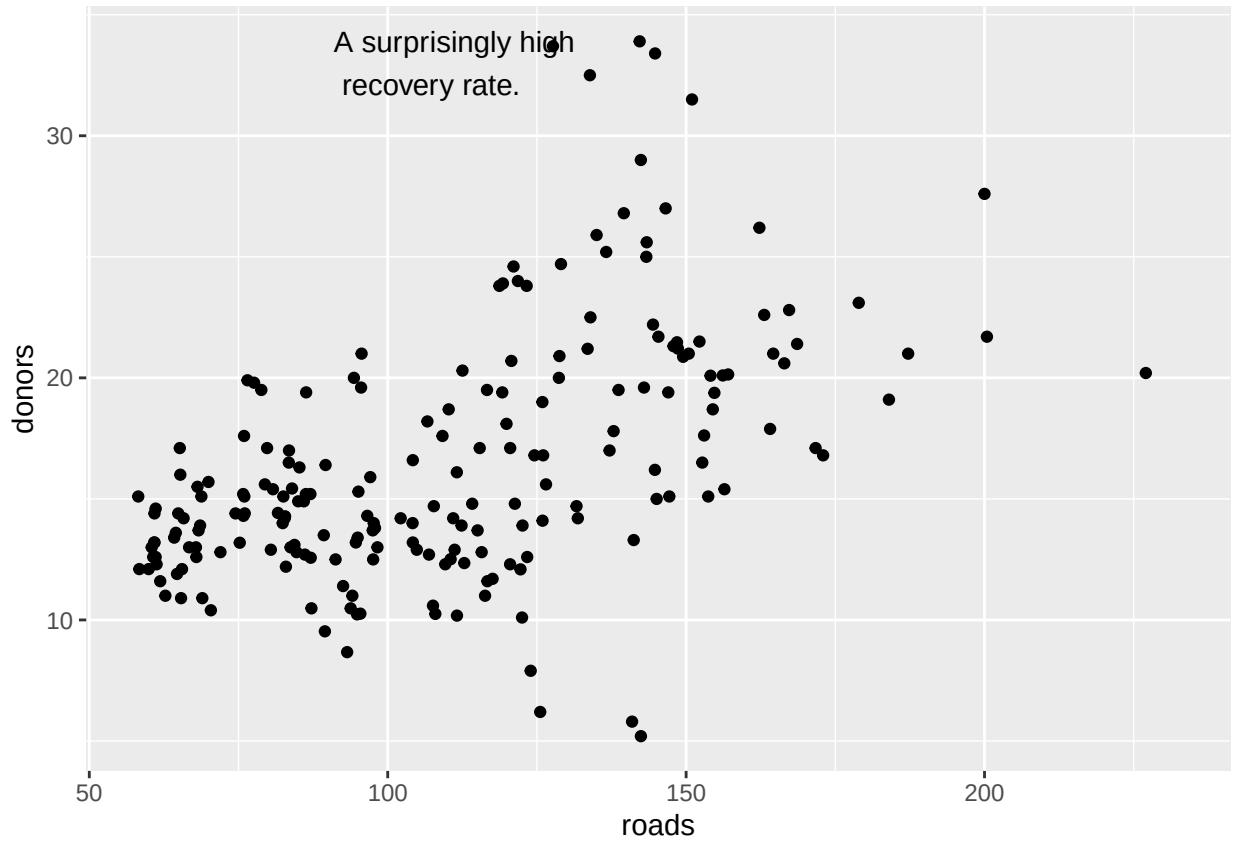

Podemos fazer uso dos outros geoms, e desenhar retângulos, retas e setas. Vamos adicionar um retângulo para resaltar a quais pontos nossa observação se refere:

```
p <- ggplot(data = organdata,
            mapping = aes(x = roads,
                          y = donors))

p + geom_point() +
    annotate(geom = "rect",
             xmin = 125, xmax = 155,
             ymin = 30, ymax = 35,
             fill = "red", alpha = 0.2) +
    annotate(geom = "text",
             x = 157, y = 33,
             label = "A surprisingly high \n recovery rate.",
             hjust = 0)
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

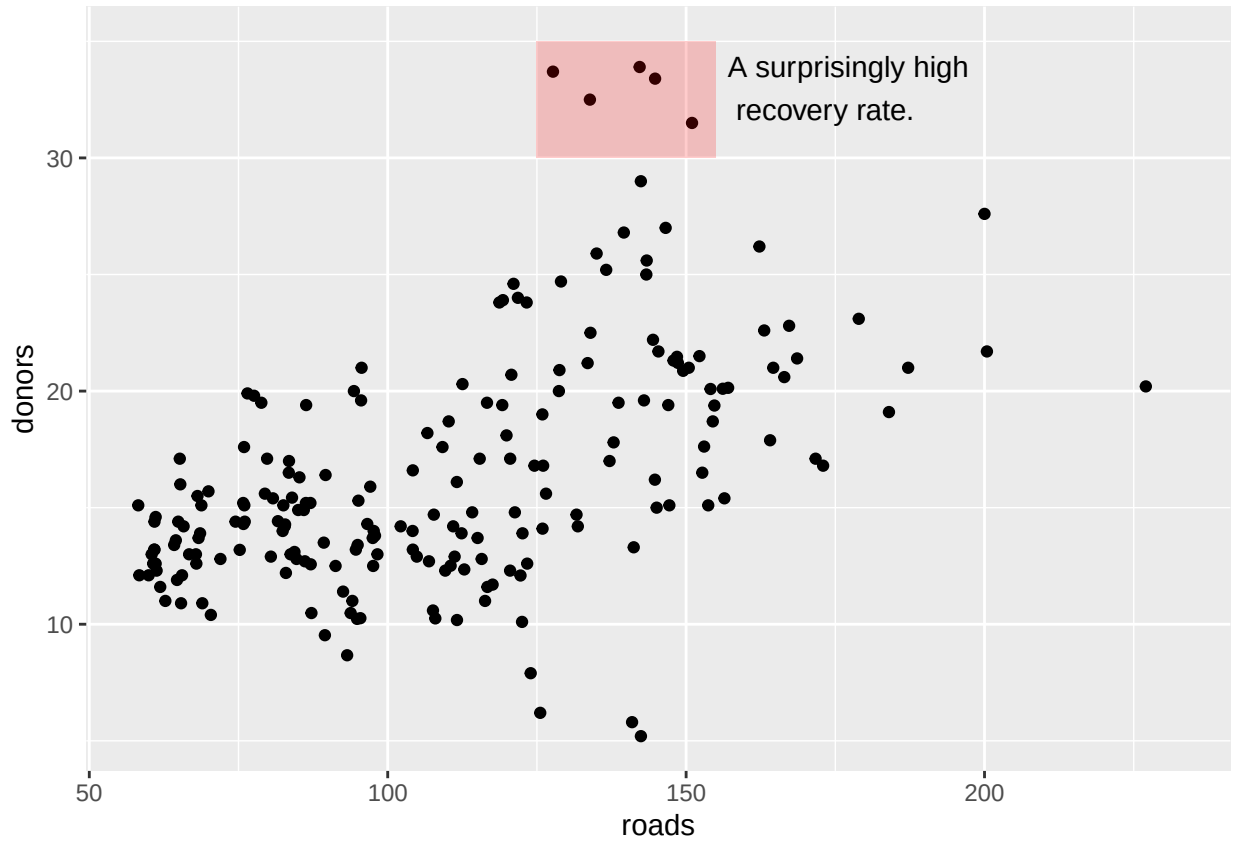

Escalas, guias e Temas

A seguir temos um gráfico simples de dispersão:

```
p <- ggplot(data = organdata,
            mapping = aes(x = roads,
                          y = donors,
                          color = world))
p + geom_point()
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

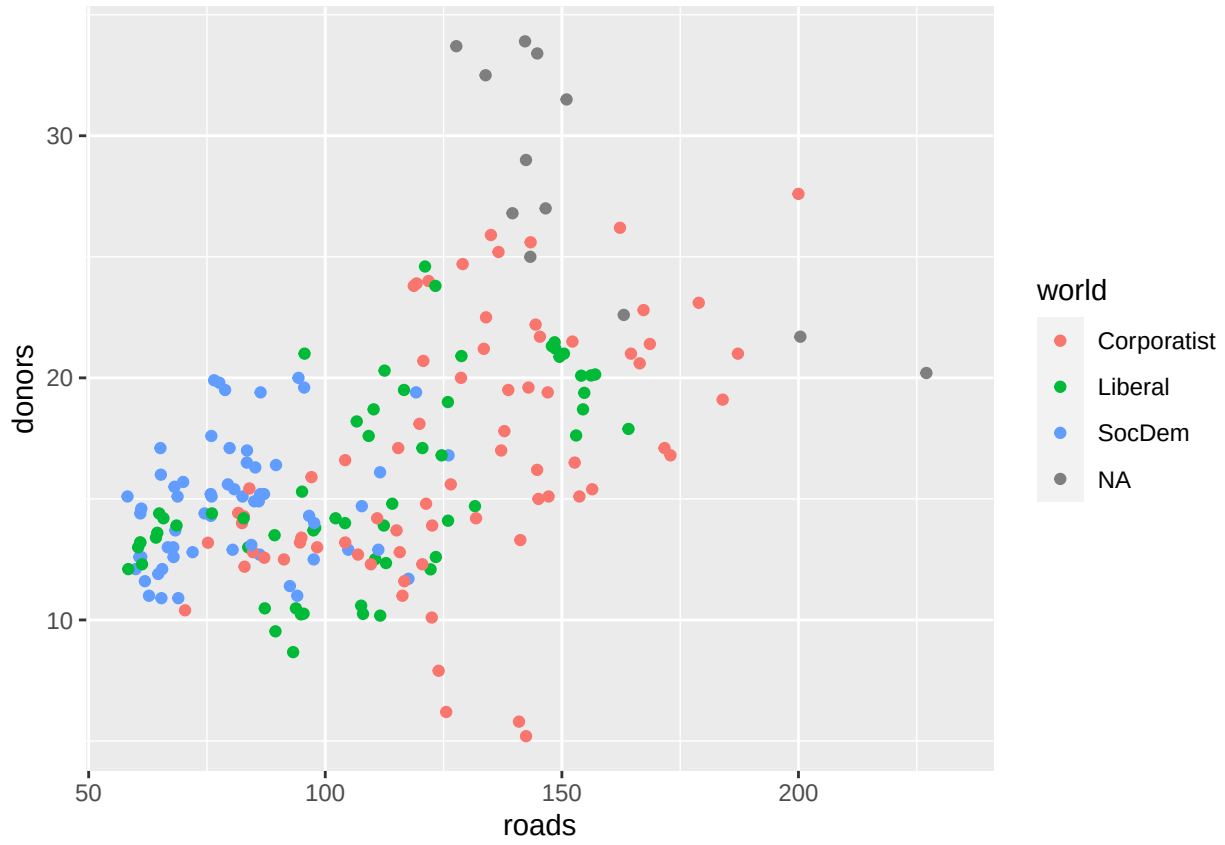

Podemos mudar a escala do eixo através de uma função do tipo **scale_mapping_kind()**, além de mudar as escalas podemos definir as posições e os labels para as marcações do eixo. Como podemos ver a seguir:

```
p <- ggplot(data = organdata,
            mapping = aes(x = roads,
                          y = donors,
                          color = world))
p + geom_point() +
    scale_x_log10() +
    scale_y_continuous(breaks = c(5, 15, 25),
                       labels = c("Five",
                                  "Fifteen",
                                  "Twenty Five"))
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

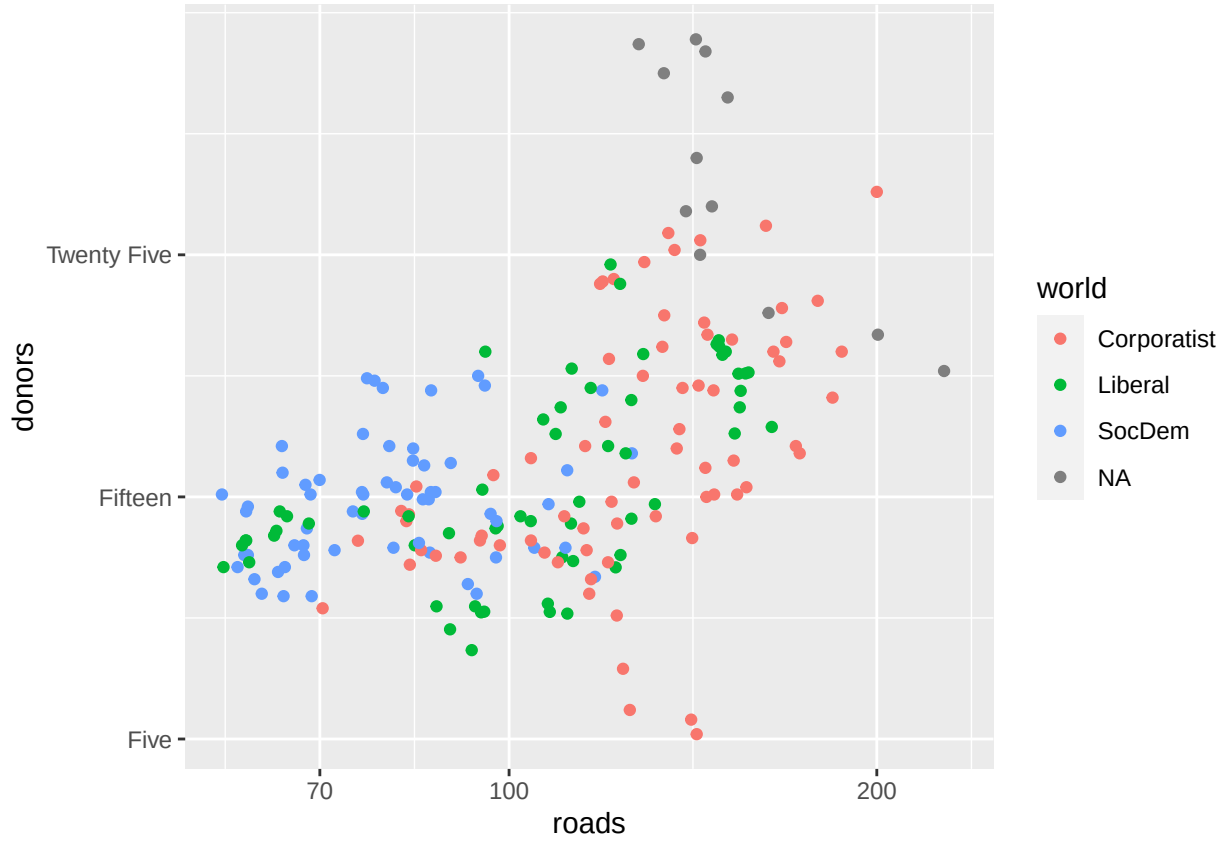

Porém, se quisermos mudar os labels da legenda ou dos eixos em si, faremos isso utilizando a função **labs()** :

```
p <- ggplot(data = organdata,
            mapping = aes(x = roads,
                          y = donors,
                          color = world))
p + geom_point() +
    scale_color_discrete(labels = c("Corporatist",
                                    "Liberal",
                                    "Social Democratic",
                                    "Unclassified")) +
    labs(x = "Road Deaths",
         y = "Donor Procurement",
         color = "Welfare State")
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

Por fim, para o caso de não querermos a legenda, podemos utilizar o **guides()**.

```
p <- ggplot(data = organdata,
            mapping = aes(x = roads,
                          y = donors,
                          color = world))

p + geom_point() +
    labs(x = "Road Deaths",
         y = "Donor Procurement") +
    guides(color = FALSE)
```

```
## Warning: Removed 34 rows containing missing values (geom_point).
```

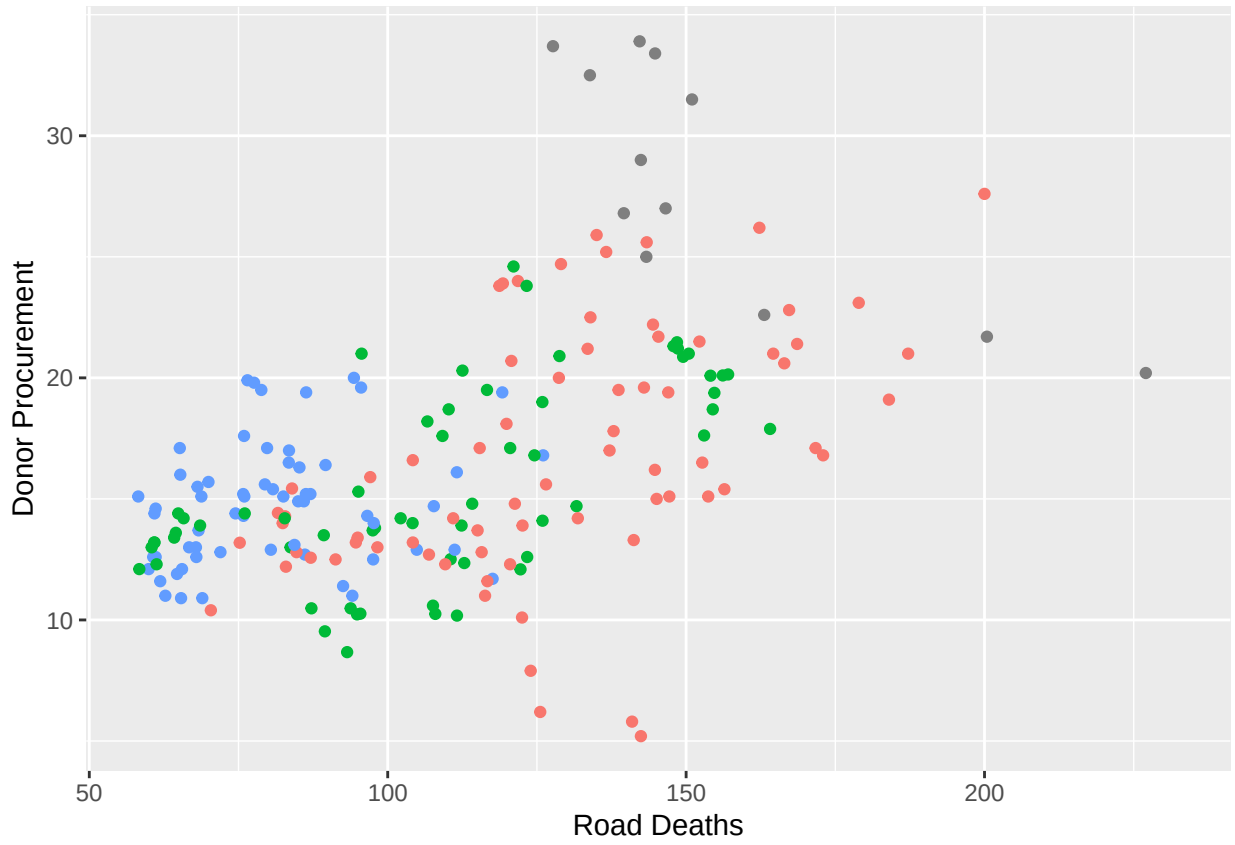

Revisitando um Gráfico

Vamos agora aplicar o que foi discutido no capítulo revisitando um gráfico do trabalho **"Casas para Alugar"** :

```
library(ggExtra)

Tabela <- read.csv('Dados limpos')
```

Trata-se de um gráfico de dispersão da metragem do imóvel pelo valor total para se alugar o imóvel:

```
graf <- Tabela %>%
  filter( !is.na(Tabela) ) %>%
  ggplot() +
  geom_point(mapping = aes(x = area, y = total, color = total)) +
  scale_color_gradient(low = "orange",high = "red") +
  theme(legend.position="none")

graf <- ggMarginal(graf, type="histogram", fill = "darkorange")

show(graf)
```

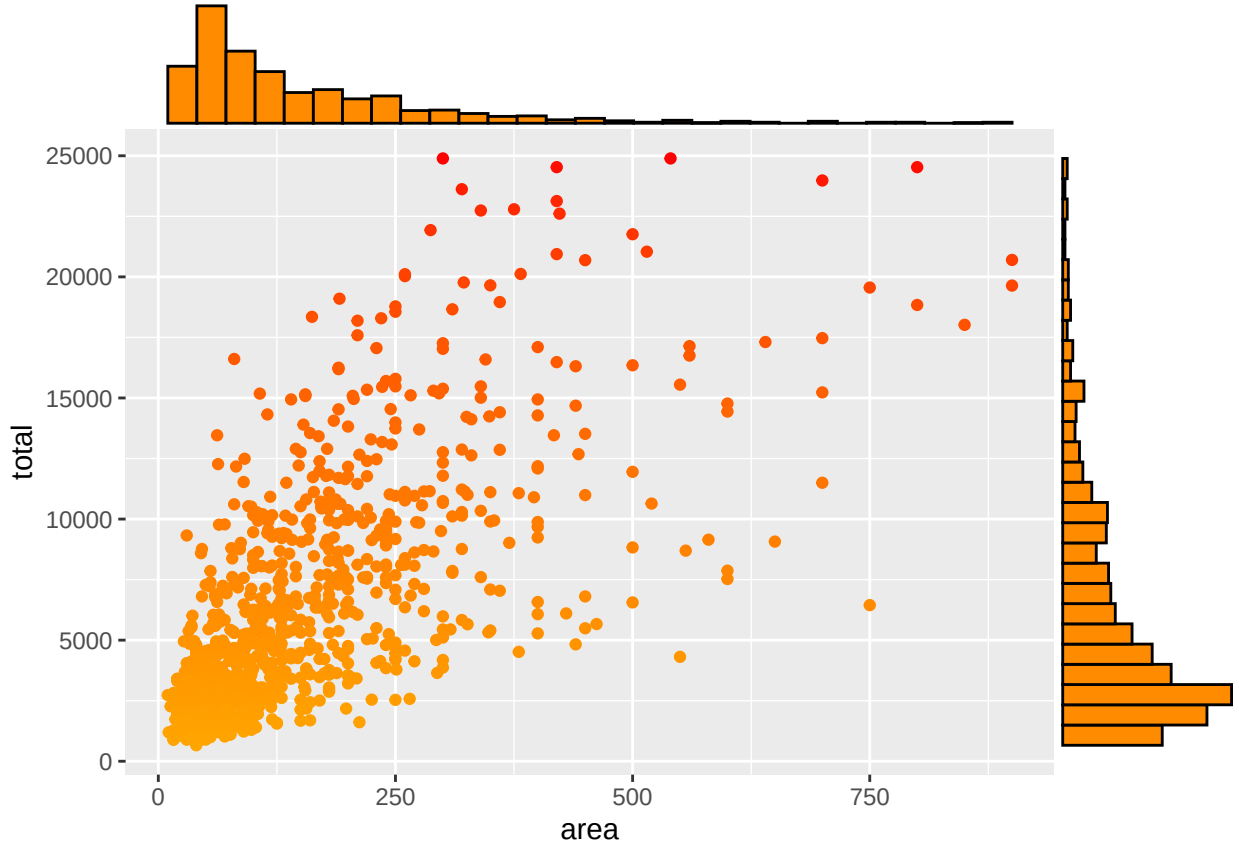

Podemos omitir a legenda de modo mais elegante utilizando a função **guides()**,

```
graf <- Tabela %>%
  filter( !is.na(Tabela) ) %>%
  ggplot() +
  geom_point(mapping = aes(x = area, y = total, color = total)) +
  scale_color_gradient(low = "orange",high = "red") +
  guides(color = FALSE)

graf <- ggMarginal(graf, type="histogram", fill = "darkorange")

show(graf)
```

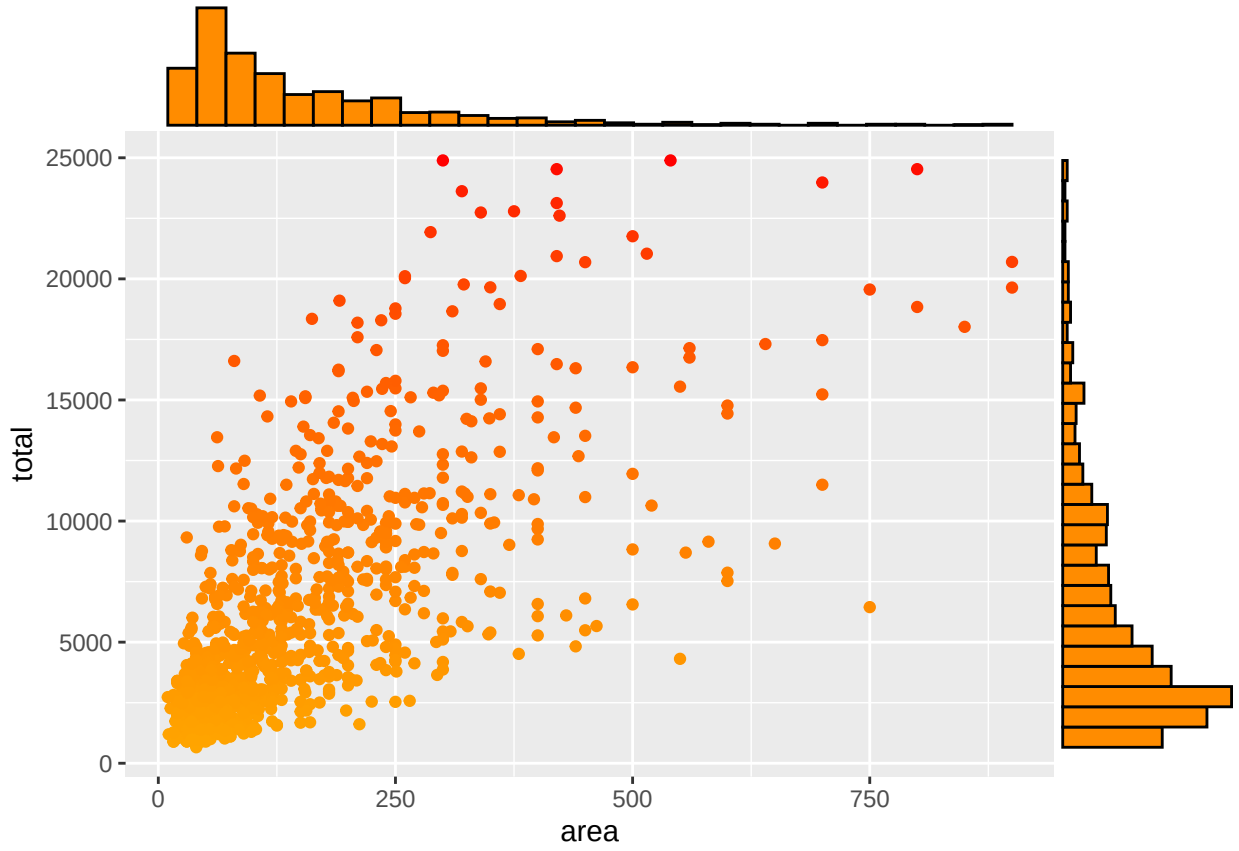


```
Tabela %>% filter(rent.amount > 12000) %>%
  ggplot(aes(x = area, y = rent.amount, colour = animal)) + geom_point()
```

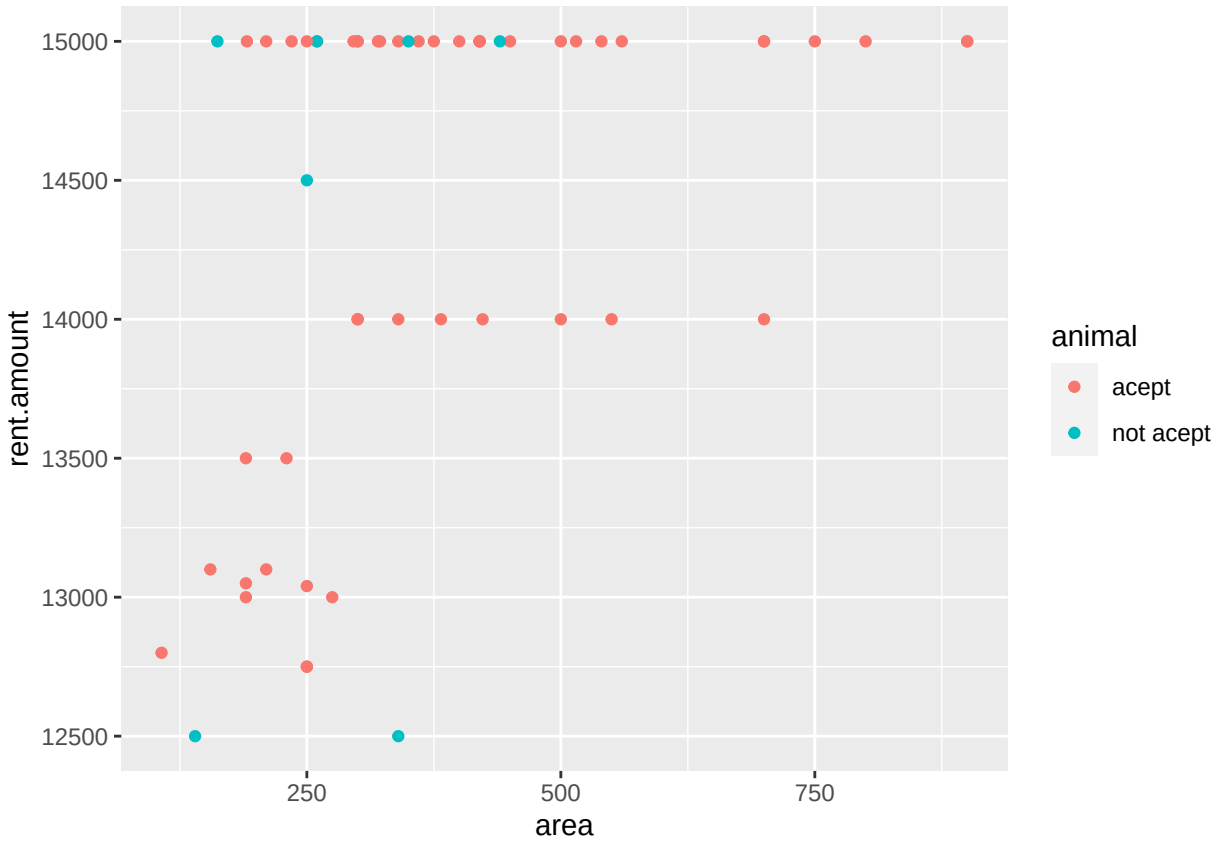

Adicionei desenhos e um texto no gráfico diretamente utilizando **annotate()**:

```
Tabela %>% filter(rent.amount > 12000) %>%
  ggplot(aes(x = area, y = rent.amount, colour = animal)) +
  geom_point() +
  annotate(geom = "rect",
           xmin = 125, xmax = 910,
           ymin = 15100, ymax = 14900,
           fill = "yellow", alpha = 0.2) +
  annotate(geom = "rect",
           xmin = 250, xmax = 750,
           ymin = 14100, ymax = 13900,
           fill = "yellow", alpha = 0.2) +
  annotate(geom = "text",
           x = 350, y = 14500,
           label = "Observe as faixas de valores \n invariantes à metragem do imóvel",
           hjust = 0)
```

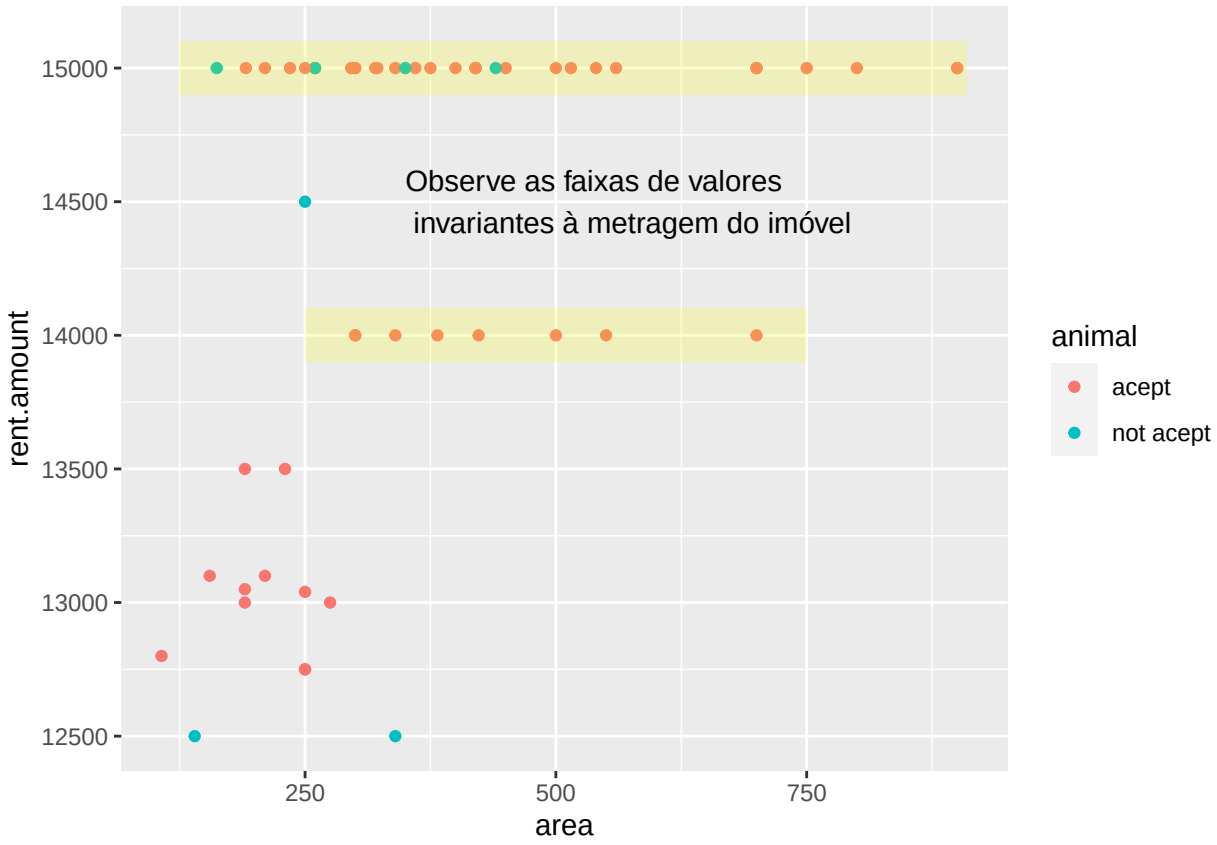
15000
14500
14000
13500
13000
12500
rent.amount
250
500
750
area
Observe as faixas de valores
invariantes à metragem do imóvel
animal
acept
not acept